

教材形式化中的审核历史

测量、比较与统计分析

中文版 – 第 0.5.0 版

2026 年 9 月 6 日

摘要

教材形式化项目反复把数学任务写成候选 Lean 文件，检查和审核提交，并根据问题记录修改。保存的候选、审核输入、判断和问题说明，使这些决定可以追溯，也构成了本次回顾性评价的材料。报告先解释保留证据如何成为有向连接，选定候选修改如何形成连续片段，以及失败起点路径如何观察到首次记录通过或退出；随后区分评价器检查的性质与题意符合性，建立候选与标准的四格比较，并推导粗略测量、缺失信息和停止规则带来的限制。一个历史定义见证和一次穷尽输入的布尔对照，展示了形式接受与任务符合之间的具体缺口。在选定历史中，修改前后配对的记录接受情况平均上升，而固定失败起点路径中，后续步骤的通过比例低于首步。任务加权比较、配对 t 计算、任务整群重抽样、精确 McNemar 计算和两组过程模型分别保留各自的结果变量与分母。报告假定读者掌握微积分、概率、线性代数和基础统计推断。结论在明确假设下描述保留证据，不将记录接受当成独立的数学正确性测量。

目录

1 审核历史是怎样产生的	4
1.1 从教材题目到经过审核的 Lean 文件	4
1.2 为什么从失败到通过仍需要解释	4
1.3 第二个流程：把工作记录整理成分析数据	5
1.4 阅读顺序与定义查找	5
2 从保留记录到分析单位	5
2.1 任务、候选、审核记录与证据签名	5
2.2 一道题、三次提交、两条连接、一个片段	6
2.3 从证据到 2,645 条可定向相邻连接	6
2.4 哪些连接算候选修改：465 条与 367 条	6
2.5 把 367 条边拼成 262 个完整连续片段	7
2.6 选出 230 个失败起点，再观察 329 个步骤	8
2.7 为什么选定执行样本是 14 对候选	8
2.8 构造比较、定义见证与布尔任务	8
3 评价量与四格比较	9
3.1 候选、标准、环境与分数	9
3.2 公理政策测量及缺失、无效分数	9
3.3 四格、条件差与交互量	10
3.4 两要素夏普利分摊	11
3.5 历史审核：记录标签与部分可观察的条件	11
4 数学分析：证据能够确定什么	12
4.1 测量分组与有限错误下界	12
4.2 为什么接受记录本身不能识别准确率	13
4.3 停止、观察资格与路径退出	14
4.3.1 从重建片段到实际观察路径	14
4.3.2 恒定条件通过概率与可预测观察	14
4.3.3 鞅表述	15
4.3.4 随机分母下的平均	15
4.3.5 退出与成功路径筛选	16
4.4 部分表格与逻辑约束	17
4.5 线性比较量的识别	18
5 可执行检查究竟确认了什么	19
5.1 编译、目标提取、公理与题意	19
5.2 针对直接假设结论的狭窄检查	19
5.3 四种评价方法与诊断可答性	20
5.4 为什么空集能区分两个定义	20
5.5 对一个布尔任务穷尽行为检查	21
5.6 结果重建与矛盾输入的拒绝	22
6 记录判断的配对统计	22
6.1 结果定义：记录通过	22
6.2 任务等权与边等权平均变化	23
6.3 为什么 465 条边不是 465 个独立观察	24
6.4 配对 t 计算及其参照假设	24
6.4.1 平均差与标准误	24
6.4.2 零假设与观察统计量	24
6.4.3 参照分布与适用范围	25
6.5 任务整群重抽样与参考区间	25
6.6 三种选取规则下的结果	25
6.7 为什么零诊断差值给出未定义的 t 统计量	26
6.8 八对编译结果：精确 McNemar 检验	27
7 沿固定失败起点路径观察	28

7.1	固定分析集合、首次通过停止与退出	28
7.2	逐步计数、风险集与累计比例	28
7.3	首步和后续步骤的比例具有不同构成	29
7.4	两组对数赔率模型及其系数	30
7.5	任务聚类协方差与参考检验	31
7.6	为什么选取有后续观察的任务会改变首步组	32
8	把结果联系起来	32
8.1	数学结果的含义	32
8.2	为什么两种历史趋势可以同时成立	33
8.3	逻辑、统计与题意上的不确定性	33
8.4	后续比较研究的条件	33
9	局限与复现	34
9.1	结果没有建立什么	34
9.2	本版范围	34
9.3	源文件与复现	34
9.4	智能体辅助	34
A	定义与方法索引	35
B	来源与相对目录	35

1 审核历史是怎样产生的

1.1 从教材题目到经过审核的 Lean 文件

这个项目把概率教材中的定义、定理、例题和习题写成 Lean 文件。Lean 是一种编程语言，也是一套检查形式化证明的系统。对于某个教材任务，编写智能体根据题目文字及相关数学材料写出候选文件，先检查它能否构建，再由审核智能体对照原题和所提供的审核要求，检查这个送审版本。审核者留下判断，并在适用时记录供编写者修改的问题。编写者随后可以提交另一个版本，再次接受检查和审核。

审核所问的不只是编译器是否接受文件，还包括：形式定义或陈述是否表达了题目要求的数学，证明是否处理了应有的论证，依赖和假设是否符合适用规则。因此，一次失败可能促使编写者修改陈述、证明或辅助定义；后来的审核也可能重新检查已经接受的文件。这些活动留下了不同材料：题目文字、保存的候选版本、构建结果、审核输入与要求、判断标签，以及问题说明。

这些记录首先服务于实际工作，随后才成为研究材料。编写者要知道改哪里，审核者要知道正在看哪道题的哪个版本，后来的维护者则要理解某个结果为什么曾被接受，又为什么重新审核。保留旧证据，才能把一次判断与当时可用的材料联系起来。保存被拒绝的候选或较早的审核，并不表示它仍是当前成果；这些记录也不是每一次编辑、每一次模型调用的完整日志。

以上是保留的流程文档和历史材料所支持的共同工作模式。档案还包括对正式成果的复查、外部成果审核，以及同一次审核的不同文件表示；要求、工具和记录方式都曾变化。因此，不能假定每条历史记录都由今天的形式化系统按照同一套实现产生。附录 B 列出了这段背景说明所依据的材料。




图 1: 反复出现的工作模式，证据随各项活动保留下来。图中并不假定每条历史记录都经历了每一个方框。

1.2 为什么从失败到通过仍需要解释

一次提交涉及几个不同的问题：软件能否处理它？证明是否遵守指定依赖规则？形式陈述是否表达了原题的数学内容？这些问题的答案可能不同。例如，“假设结论成立，则结论成立”可以具有形式上有效的证明，却仍未解决原题。Lean 文档也区分了证明的有效性检查与陈述含义的核查 [2]。

现在假设较早的审核拒绝了候选，较后的审核接受了它。编写者可能确实修正了数学问题，但题目要求或审核者掌握的证据也可能变了，先前的问题还可能没有再次被注意到。两个判断标签本身无法区分这些解释。历史值得研究，正是因为它不只保留最后一次通过：它还提供了一部分有关审核对象、检查和中间结果的证据。

1.3 第二个流程：把工作记录整理成分析数据

本研究从编写和审核活动结束后开始。首先整理保留证据，把它们与任务和候选标识关联起来，登记可以取得哪些审核材料与上下文。接着，沿用档案规定的同任务相邻配对，判断哪些配对能确定时间方向，再分类每条连接表示什么活动。候选改变、正式成果复查和同次审核的第二种文件表示，分别保留自己的含义。完成分类以后，才把符合条件的修改连接拼成连续历史。

由此产生两个历史问题。把一次选定修改的前后端点配对，可以询问记录判断怎样变化；从一次明确失败开始沿连续历史观察，则可以询问哪一步首次记录通过，或在哪儿结束了观察而未见通过。它们来自同一档案，却使用不同的数据构造。第 2 节会先解释单位、筛选规则和计数，再使用统计结果。

研究还用明确规定的检查考察部分保存候选，并使用人为构造的比较，以及一个可以穷尽全部输入的小任务。这些材料回答另一类问题：评价器究竟能提供候选的哪些信息？据此，报告研究三个相互关联的问题：

1. **测量**：一项指定检查确认了什么，又留下了什么没有解决？
2. **比较**：在两条明确标准下分别比较两个候选，哪些量发生了变化？
3. **记录过程**：判断怎样在选定修改前后变化，又怎样分布在保留的失败起点历史中？

即使缺少独立的数学正确性判断，我们仍能统计记录中的决定；此时，统计解释必须保持在这些决定的范围内。

1.4 阅读顺序与定义查找

章节沿用便于查阅的顺序：对象及其选取方式、评价量、数学论证、可执行证据、配对统计，以及观察到的过程。定义规定各项分析所用的对象和量，命题说明明确假设能够推出什么。说明性例子用于解释计算，不是额外实验。

第 2 节定义任务、候选、记录、连接和连续片段。第 3 节介绍分数，以及把两个候选放在两条标准下分别检查的四格比较。第 4 节给出测量、停止和识别方面的论证，第 5 节说明保留的可执行检查。第 6 节和第 7 节展开配对与过程统计。附录 A 提供带页码的定义索引，附录 B 将分析连接到随附文件。

报告假定读者掌握基础微积分、概率、线性代数、统计推断及其常用记号，在需要时介绍项目专用术语和统计构造。每个平均数都说明什么对象获得权重，每个比例都交代分母数的是什么。

2 从保留记录到分析单位

2.1 任务、候选、审核记录与证据签名

任务是一项数学作业，例如形式化某个指定定义，或证明某条指定定理。候选是为该任务提交并保存的一个版本。同一任务可以有多个候选，同一候选也可以被审核多次。审核记录保留对一个对象的判断，以及能够取得的相关证据和上下文；这个对象可能是候选，也可能是正式成果。

分析使用证据签名标识保留下来的、由审核者产生的证据。整理后的主要集合包含 3,231 个这样的签名。这是按档案识别规则计算的证据条目数，不是题目数，也不保证发生了 3,231 次彼此分开的审核执行。例如，同一次审核的原始结果文件和整理结果文件，可能作为不同证据条目保留下来。后续分类会识别其中一些关系，而不把它们解释为独立重复审核。

2.2 一道题、三次提交、两条连接、一个片段

考虑一个说明性定理任务，先后有甲、乙、丙三个提交版本，相应审核记录为 r_A, r_B, r_C ，判断依次是失败、失败、通过。假设甲到乙、乙到丙都符合下面将定义的候选修改规则，而且两条连接的中间端点确实是同一条审核记录 r_B 。这个任务就提供了：

- 一道题和三个送审候选版本；
- 本例中的三条审核记录；
- 两条有向连接，也称边： $r_A \rightarrow r_B$ 和 $r_B \rightarrow r_C$ ；
- 在 r_B 处拼接这两条边得到的一个连续片段。

因此，两条边共有四次端点出现，却只有三条不同的端点记录。重复使用中间记录，既影响重建，也影响统计依赖。连接描述两个保留观察之间的关系，并不计算其间发生了多少次编辑或模型调用。

连续性要求共享同一条审核记录，仅有相同题目标识或相同候选文本还不够。假设后来的丁版本之前出现了正式成果复查、不符合选定规则的连接，或时间顺序尚未解决的缺口，就不能仅因题目未变而把丁接入原片段。如果丁与更晚的戊版本又形成一段合格序列，同一道题便贡献第二个片段。这种构造没有断言实际工作曾在缺口处停止。

完整片段与针对某个问题实际观察的部分也有区别。在“失败、失败、通过”的例子中，观察到首次通过会使用两条边；在另一个说明性的“失败、通过、失败”片段中，完整重建仍可能包含两条合格边，但首次通过分析只使用第一条。它不会把最后的失败当成通过之前的失败。这些例子用于解释规则，不是新增观察。

2.3 从证据到 2,645 条可定向相邻连接

为了研究审核之间发生了什么变化，分析从档案已经固定的同任务相邻关系出发。只有一对原始相邻记录的两端签名都属于整理后的主要集合时，才保留这对记录。这里不会先删掉中间记录，再把剩余记录中变成邻居的两条重新连接起来；原有缺口因此仍然保留。

这项成员规则得到 2,738 对记录。其中 93 对按已声明的时间戳规则无法确定先后，包括时间相同或精度不足等情况；它们仍作为无向证据保留，不进入前后比较。其余 $2,738 - 93 = 2,645$ 对提供有向连接。这个方向是根据记录时间和标识建立的顺序代理，不证明一次审核导致了下一事件。也不能简单用 3,231 减去题目数得到连接数，因为规则保留的是原始相邻关系，而不是筛选后重新搭成无缺口链条。

即使连接已有方向，也不一定表示修改。前一端可能审核候选，后一端审核文本相同的正式成果；两端也可能都审核正式成果；原始结果文件之后还可能只是同次审核的整理版本。因此，下一步需要根据审核对象、主要 Lean 文本、来源、已登记上下文，以及此前的结构化问题来分类活动。通过或失败标签本身不用于决定这个活动类别。

2.4 哪些连接算候选修改：465 条与 367 条

分类程序按顺序应用规则：先识别同次审核的两种文件表示，再识别明确标记的外部审核，随后检查相同登记条件下是否有两次独立执行的明确证据。条件相同却无法证明执行分开的情况仍归为未解决。程序接着识别候选以相同主要文本落地到正式成果的情况。处理过这些优先类别后，才判定候选修改：后一审核对象必须是候选，而且两端的主要 Lean 文本不同。剩余的正式成果到正式成果连接归为正式复查，其他无法解决连接保留为混合或不明类别。

在候选修改类别内，高置信表示前一审核包含结构化问题；没有这种问题记录时，标为中置信。这是可以重复计算的规则标签，不是数值置信水平，也不认证某个数学问题已经修复。规则识别的是记录问题之后出现了改变的候选，并未独立确认改变解决了那些问题。程序将这一类别命名为 `candidate_repair`；正文使用“候选修改”，以保留这个区别。

最终类别对全部有向连接形成如下划分：

表 1: 2,645 条有向连接的活动分类。计数单位是连接，不是执行次数或题目。

类别	数量	含义
候选修改	465	主要文本改变，后一对象为候选
候选落地	241	候选之后是主要文本相同的正式成果
正式成果复查	1,176	两端对象均为正式成果
外部审核	207	至少一端来源明确标记为外部审核
同次审核的两种表示	166	已识别的原始与整理结果配对
同条件的不同审核	0	需要分别执行的明确证据
混合或不明确	390	现有字段不足以确定活动
合计	2,645	每条连接只归入一类

465 条候选修改边涉及 250 个不同任务，分为 367 条高置信边和 98 条中置信边。完整的 465 条边用于第 6 节的修改配对分析。其中，高置信敏感性分析使用 367 条边，涉及 207 个任务。任务数统计的是筛选后出现的不同标识；与互不重叠的边数不同，各子集的任务数未必可以相加，因为同一个任务可能同时贡献两类边。

2.5 把 367 条边拼成 262 个完整连续片段

过程问题的重建只使用 367 条高置信候选修改边。从没有合格前驱的边出发，仅当前一条边的较后审核标识，与下一条边的较早审核标识相同时，才追加那条合格边，直到找不到下一条。结果称为极大连续片段，即在所选边集合内已经无法继续延伸的链。档案称它为片段，后面的章节也使用路径或过程。

这样的归组让每条选定边恰好进入一个片段，共得到 262 个片段。遇到不合格连接、时间顺序未解决的边界，或已观察连接结束时，片段便结束。记录通过本身不终止这次重建：通过标签将在下一项分析操作中使用。表 2 展示边与片段之间的数量对应。

表 2: 完整重建片段的长度。此时尚未筛选失败起点，也尚未在首次通过处停止。

每片段边数	片段数	贡献的边数
1	212	212
2	38	76
3	1	3
4	5	20
5	3	15
12	2	24
17	1	17
合计	262	367

第二列数片段，第三列数片段所含的边。归组本身没有删除任何边，所以 262 个片段仍涉及原来 367 条边对应的 207 个任务。同任务的多个片段在重建中仍是分开的路径，在统计归组时则仍由同一任务标识联系起来。

2.6 选出 230 个失败起点，再观察 329 个步骤

过程分析询问明确记录失败之后发生了什么，所以选取第一条审核明确写为失败的 230 个片段，把另外 32 个排除在这个问题之外。选中的片段属于 182 个不同任务。230 数的是起始片段，182 数的是它们涉及的任务标识；两者都不是独立审核执行的数量。

现在，在每个选中片段内，观察到第一个较后审核记录通过时停止；如果没有出现通过，就在片段边界停止。这第二项操作改变的是已观察长度，不改变此前固定的片段成员。对选中片段应用该规则，共得到 329 个观察步骤。每一步是一条合格边，结果取自它的较后审核。230 条路径中，206 条以首次记录通过结束，24 条到片段边界时仍未见通过。原始失败记录是起始条件，不额外算作一个观察步骤。

因此，329 不是把全部 367 条重建边换一个名字：其间经过了失败起点筛选与首次通过截取。同样，206/230 不是 182 个任务中的成功比例，因为同一任务可以贡献多条路径。第 7 节将继续解释逐步变化的分母，并区分路径退出与任务永久失败。

表 3: 活动分类之后的两条历史分析路线。每行均说明操作及其计数单位。

操作	结果与用途
保留全部候选修改连接	465 条边、250 个任务：配对的记录标签变化
进一步限于高置信边	367 条边、207 个任务：配对敏感性分析，以及路径重建的输入
在共享审核端点处拼接高置信边	262 个完整片段：先确定连续性，再按结果筛选
保留明确失败起点的片段	230 个片段、182 个任务：固定的过程分析集合
沿每个选中片段观察到首次通过或边界	329 个步骤；206 个通过终点和 24 次退出

2.7 为什么选定执行样本是 14 对候选

较大历史描述记录判断。为了考察明确规定的评价器能够确认代码的哪些性质，研究另外从修改材料中挑选一份较小的候选配对样本：6 对开发候选与 8 对按任务分开的留出候选，共 14 对、28 个候选端点。同一任务不会拆到开发和留出两组。这是回顾性研究中的选取分区；此前已经接触过部分档案，因此不能把它解释为完全盲态、独立抽样的实验。

每对候选接受两种评估。一种检查允许的公理依赖，另一种检查主定理不能直接假设完整结论这一狭窄要求。每项评估都把两个候选分别放在两条明确标准下考察，四种候选与标准的组合构成一张四格表，第 3.3 节会给出定义和完整计算。因此共有 $14 \times 2 = 28$ 张历史表，它们重复使用同一批 14 对候选。第 5 节报告测量结果；本版没有增加新的执行。

2.8 构造比较、定义见证与布尔任务

研究还询问：在人为安排的已知或缺失分数组合中，比较方法是否按预期工作？7 张构造表服务于这个问题，与 28 张历史表合起来，共有 35 张用于考察比较程序的表。这个总数数的是表，不是 35 个独立抽样任务。第 5 节会解释每张表所提出的六个诊断问题。

另一项历史定义见证考察一道题的两版候选，它们对“可数”采用了不同约定。6 条已证明命题确认候选、明确参照与空集之间的关系；它们描述一个案例，并不表示六次独立成功。

最后，一个有限布尔任务要求当且仅当两个输入不同时输出真。全部输入只有四种，因而可以给出完整行为参照。研究有意设计了 9 种实现：3 种符合要求、5 种不符合要求，以及 1 种编译失败对照。第 4.1 节使用其中 8 种可执行实现推导测量的局限，第 5.5 节列出完整结果。一个任务的九种实现，并不提供九个独立抽样数学任务。

这些材料用途相连，却各有自己的分母。历史修改与路径分析描述经过选择的记录；选定执行与构造案例检查具体评价方法，或给出反例。不能把它们的计数相加得到统一样本量，也不能视为同一项统计结论的独立重复验证。

3 评价量与四格比较

3.1 候选、标准、环境与分数

考虑这样一个程序任务：输入两个布尔值，当且仅当两者不同时输出真。一个候选程序总是输出假，另一个正确计算异或。两者都可能通过 Lean 编译，但只有后者在每种输入下都给出所需答案。因此，给出分数之前，需要先说明它衡量的是哪一种性质。

用 C 表示候选成果，包括保存的代码和事先选定的检查目标。这个目标称为声明，也就是代码中有名字的定义或定理；预先选定它，便固定了评价对象。用 R 表示审核标准，规定做什么检查以及何时接受；用 E 表示执行环境，包括编译器、库、搜索路径和运行设置。评价程序 g 则在环境 E 中，按标准 R 检查候选 C 。

当一次检查确实取得了有效的数值结果时，我们把这个分数写成

$$q = g(C, R; E).$$

这里的 q 就是指定程序返回的分数。比较保持环境不变。本报告使用的接受分数没有量纲：1 表示指定检查通过，0 表示未通过。它们是这项检查的判断，并不是数学内容正确的概率。

使用 g 时，仍需说明实际程序、检查目标、标准和证据；一个函数符号本身并不能定义通用的数学正确性评分。下面先看本次核查实际实现的程序。

3.2 公理政策测量及缺失、无效分数

发布包中的 `evaluate_sources.py` 实现的是范围较窄的公理政策检查。它保存源代码，为事先选定的声明追加查询命令，调用已记录的 Lean 4.31.0 编译器，然后提取两项信息：声明打印出来的类型，以及系统报告的公理依赖。类型描述这个声明的接口或命题；公理列表记录这个声明依赖的假设。这些观察很有用，但任何一项都不会自动说明原任务究竟想表达什么。

在这个程序中，标准 R 提供允许使用的公理名单。当且仅当提取出的每个公理都在允许名单中时，分数为 1；只要发现至少一个不允许的公理，分数就是 0。例如，若已成功提取的依赖中出现 `sorryAx`，而标准禁止它，则得到 0。空的公理依赖列表可以通过这样的标准，但“没有获得编译器输出”不等于“依赖列表为空”。Lean 的文档同样区分证明的有效性与被证明命题的含义。^[2]

在比较分数之前，程序还会用固定打印设置检查两份声明的类型文本是否完全相同。这是一个保守的接口匹配条件。它仍不能确定行为：前面的两个布尔程序都可以具有 `Bool -> Bool -> Bool` 类型。打印类型不同时，本实现不建立数值比较，但这并不排除另行设计有意义的比较。

若要检查行为，可以把四种输入全部运行一遍，再与题目要求的真值表比较。后面的有限域对照正是增加了这项测试，从而取得单靠公理政策检查无法提供的证据。

检查也可能没有产生可用分数，因此还需要保留测量状态：

已测量。

指定检查确实得到了数值。已测量的零分表示这项检查实际拒绝了该候选成果。

未运行、材料缺失或结果不确定。

想问的问题有意义，但没有取得答案。例如，编译器不可用、源文件缺失、运行超时，或者没有成功提取选中的声明。这个范围较窄的公理检查不会把编译失败自动记为公理政策零分，因为它并没有取得公理测量结果。

无效或不适用。

所提议的比较缺少必要的共同含义，或者这项标准不适用于选定对象。若把这种格子当成一个尚未知晓的数值，就已经偷偷假定了一个尚未被证明合理的比较。

怎样编码取决于所问的问题。研究编译成功与否时，可以把编译失败记为零；公理政策检查尚未取得公理测量时，则不能作同样处理。

3.3 四格、条件差与交互量

现在固定评价程序和执行环境，在两个标准下分别比较两个候选成果。其中， C_0 和 C_1 是两个候选成果， R_0 和 R_1 是两个审核标准。记

$$q_{ij} = g(C_i, R_j; E), \quad i, j \in \{0, 1\}.$$

下面的例子给出四种候选与标准组合的分数。

下面是一个用于说明计算的例子，不是新做的实验。仍然使用刚才的两个布尔程序： C_0 总是输出假， C_1 则在两个输入不同时输出真。让 R_0 只检查输入“假、假”，该输入的要求输出是假；让 R_1 检查全部四种输入。按“假、假”“假、真”“真、假”“真、真”的顺序，要求的输出依次是假、真、真、假。这个例子中的 g 表示：“运行标准指定的输入；所有输出都符合要求就给 1，否则给 0。”它是为这个例子定义的行为测试程序，不是发布包中只测公理政策的程序。

候选成果	R_0 : 一个输入	R_1 : 全部四个输入
C_0 : 总是输出假	$q_{00} = 1$	$q_{01} = 0$
C_1 : 计算异或	$q_{10} = 1$	$q_{11} = 1$

先保持审核标准不变，比较两个候选成果。用 $D_{C|R_0}$ 表示在 R_0 下，第二个候选成果的分数减去第一个候选成果的分数。 $D_{C|R_1}$ 则是在 R_1 下作同样的比较。沿着两列表格分别向下读，得到

$$\begin{aligned} D_{C|R_0} &= q_{10} - q_{00} = 1 - 1 = 0, \\ D_{C|R_1} &= q_{11} - q_{01} = 1 - 0 = 1. \end{aligned}$$

只测一个输入时，检查分不出这两个程序；测遍四种输入时，就能分出来。所以，报告中的候选成果差异，取决于比较时固定的是哪一个标准。

接下来保持候选成果不变，比较两个标准。沿着每一行分别向右读，得到

$$\begin{aligned} D_{R|C_0} &= q_{01} - q_{00} = 0 - 1 = -1, \\ D_{R|C_1} &= q_{11} - q_{10} = 1 - 1 = 0. \end{aligned}$$

扩大后的测试拒绝了错误程序，但正确程序仍然通过。第一个差值为负，只表示测试得分下降，不能解释成“标准改进使程序本身变差了”。这四个差值的单位都是分数点，不是“程序质量的百分比”。

如果沿对角线比较，就同时改变了两项要素。用 Δ 表示这个总变化：

$$\Delta = q_{11} - q_{00} = 1 - 1 = 0.$$

如果只看这两个接受标签，就会同时漏掉程序的改进与测试要求的提高。交互量记作 I ，表示标准改变后，候选成果差异改变了多少：

$$\begin{aligned} I &= D_{C|R_1} - D_{C|R_0} = 1 - 0 = 1 \\ &= q_{11} - q_{10} - q_{01} + q_{00}. \end{aligned}$$

把同样四项重新分组，还可得到 $I = D_{R|C_1} - D_{R|C_0}$ 。这里的交互量是表格的算术描述，并不证明存在某种心理上的合作或因果机制。上述四个条件差、一个对角差和一个交互量，就是本次审计所使用的六个诊断问题。

3.4 两要素夏普利分摊

从左上格走到右下格有两条路径：可以先换候选成果，再换标准；也可以先换标准，再换候选成果。无论走哪条路径，两次变化的和都等于 Δ 。如果我们决定对这两种顺序给予相同权重，就把候选成果的两个条件差取平均，作为分给候选成果的变化量；再把标准的两个条件差取平均，作为分给标准的变化量。两个分摊量分别记作 ϕ_C 和 ϕ_R ：

$$\begin{aligned} \phi_C &= \frac{1}{2}[(q_{10} - q_{00}) + (q_{11} - q_{01})], \\ \phi_R &= \frac{1}{2}[(q_{01} - q_{00}) + (q_{11} - q_{10})]. \end{aligned}$$

这就是标准的两要素夏普利分摊。[8] 在上例中， $\phi_C = (0+1)/2 = 1/2$ ， $\phi_R = (-1+0)/2 = -1/2$ 。它们的和为零，与对角线总变化一致。一般情况下，把两个式子相加，中间各项抵消，得到 $\phi_C + \phi_R = q_{11} - q_{00} = \Delta$ 。

这种分摊以分数点为单位，取决于两种顺序等权的约定。它概括的是表中已有的比较，并非从历史中恢复了因果贡献。交互量已经包含在平均数内，再加一次就会破坏总和等式。

3.5 历史审核：记录标签与部分可观察的条件

四格比较中的程序和标准是明确规定的。历史审核则较难控制：档案可能保存了判断，却只保留了产生判断的部分过程。对一次审核事件 e ，需要区分以下角色：

- Y_e 是记录中的结果标签，例如通过或不通过。在另行说明数值编码之前，它只是类别。
- O_e 是当时实际接受审查的对象，包括候选代码以及相关上下文。
- K_e 是那次审查中实际采用的有效标准。

- M_e 是审查装置或设置，例如审查者或模型、提示文本、工具以及运行配置。
- U_e 汇集这套描述没有分别记录的其余影响。这里并没有为它假定概率分布，也没有假定它与其他量独立。

于是，概念式

$$Y_e = \psi(O_e, K_e, M_e, U_e)$$

只是说：这些要素通过某种审查过程产生了结果；这个过程用 ψ 表示。它不像已经拟合的回归方程那样，提供一组可以估计的系数，也没有给出已知的 Y_e 预测规则。早期记号用 C_e^* 表示有效标准，用 ε_e 表示其余影响；这里改用 K_e 与 U_e ，是为了避免把那里的标准与四格表中的候选成果 C 混淆。

例如，合同文本的哈希值可以标识保存了哪份文字，却不能确定审核者在判断时怎样执行了它。实际标准仍可能只被部分观察到。同样，标签变化可能伴随候选、要求或审核程序的变化。后面的过程分析按明确路径规则研究记录序列，并不能单独识别这些影响。

不过，我们仍能研究：一项明确的测量能够区分什么，一个给定的观察模型会推出什么，以及现有证据能确定哪些比较。

4 数学分析：证据能够确定什么

一项测量可以回答某些问题，却把另一些问题留了下来。先考虑一个有限例子：两项检查对行为不同的程序给出了相同结果。由此可以求出，仅使用这两项检查的判断规则至少会犯多少错误。

4.1 测量分组与有限错误下界

先看已经保留的有限布尔挑战样例。它共有九个样例，其中八个可以执行，一个没有编译成功。在八个可执行样例中，三个在全部四种输入下都给出了规定输出，五个没有做到。然而，八个样例都通过了公理政策门槛和打印类型门槛。这里的“门槛”只是一个返回通过或不通过的检查。现在设想：我们只把这两个门槛的输出交给另一条判断规则，不给它代码、候选成果名称或行为测试结果。那么，这条规则面对八个样例时，收到的输入都完全相同：两个检查都通过。一条确定性规则，即“相同输入总是产生相同答案”的规则，必然对八个样例作出相同判断。

如果它把八个样例都判断为符合任务，就会错五个；如果把八个都判断为不符合任务，就会错三个。即使选择较好的一种，仍然会错三个。只对同样两个二值信号做更复杂的计算，也不能告诉它究竟是哪三个程序正确。行为检查之所以能够分辨它们，是因为它增加了另一项观察。

我们可以把这个道理写成适用于任意有限样例集的结论。用 $\mathcal{X}$ 表示正在检查的对象集合，用 n 表示对象总数，并假设 $n > 0$ 。其中一个对象记作 x 。用 $Z(x)$ 表示为这个对象保留的测量结果；它可以是一对门槛输出，不一定是单个数。用 $T(x)$ 表示参照答案：符合指定任务参照时为 1，不符合时为 0。这里的字母 T 表示二值任务答案，不是等待时间。在这个例子里，参照来自遍历四种输入的检查；这样写不意味着每项历史任务都有同样可用的参照。

把测量值同为 z 的对象放进同一组。在这一组内，用 n_{z0} 表示参照答案为 0 的对象数，用 n_{z1} 表示参照答案为 1 的对象数。这两个量的单位都是“对象个数”。再用 δ 表示一条只根据 $Z(x)$ 返回 0 或 1 的判断规则，并要求它对每个对象都作出判断。定义这条规则在有限集合中的错误比例为

$$\text{Err}_{\mathcal{X}}(\delta) = \frac{\text{判断结果}\delta(Z(x)) \text{ 与 } T(x) \text{ 不同的对象数}}{n}.$$

这是该集合中判断错误的无量纲比例，还不能当成总体中的错误概率。

命题 1 (测量把不同答案合在一起时，不可避免的判断错误). 在上述假设下，任何只使用 Z 的确定性判断规则都满足

$$\text{Err}_X(\delta) \geq \frac{1}{n} \sum_z \min(n_{z0}, n_{z1}).$$

求和遍历实际出现的不同测量值。存在一条这样的规则使等号成立。因此，能够做到零错误，当且仅当每个测量分组内部都只有一种参照答案。

证明. 固定一个测量分组。规则在整组中收到同样的输入，所以只能为整组选择同一个答案。如果选择 0，就会错判组内的 n_{z1} 个符合任务的对象；如果选择 1，就会错判组内的 n_{z0} 个不符合任务的对象。所以，这一组最少也要错两个计数中较小的那么多个。把各组最少错误数相加，再除以总对象数，就得到所述下界。在每一组中都选择多数对象的参照答案，可以达到这个下界。而一组的最少错误数为零，恰好等价于两个计数中至少有一个为零。□

对于八个可执行样例，只有一个测量分组，其中 $n_{z0} = 5$, $n_{z1} = 3$ 。代入公式可得

$$\text{最小可能错误比例} = \frac{\min(5, 3)}{8} = \frac{3}{8}.$$

若采用“两项门槛都通过，所以任务已经完成”这种解释，错误比例则是 5/8。因此，5/8 描述那条特定的“全部接受”解释；3/8 描述的是所有被限制为只使用相同两个门槛输出、并且必须作出确定性二分类判断的规则所共有的限制。二者都不是历史错误率估计，也都没有使用计算缺陷检出敏感度所需要的分母。第九个没有编译成功的样例，不能悄悄加进这个针对八个对象的计算。

如果允许规则拒绝判断，问题就变了：它可以对所有对象都不作答，从而完全避免错答，所以还必须报告它究竟回答了多大比例的对象。随机化也不能降低这里的期望最小错误数。如果规则以概率 r 选择 1，其中 $0 \leq r \leq 1$ ，则这个单一分组的期望错误数为 $5r + 3(1 - r) = 3 + 2r$ ，最小值仍然是 3。某一次随机运行的结果不一定等于其期望。这也说明了为什么命题要明确写出“确定性”和“对每个对象都回答”这两个条件。

4.2 为什么接受记录本身不能识别准确率

上一条结论假定我们已经有参照答案，讨论的是粗略测量丢失了什么。当参照答案本身缺失时，还会出现另一种困难。举一个说明用例：假设四条记录仅保留了“接受、拒绝、接受、拒绝”这四个结果。如果四个参照答案都与这些结果一致，则记录中的判断完全准确；如果每个参照答案都与之相反，则判断完全不准确。在没有其他证据约束参照答案的前提下，两种假设列表都与这四个已观察判断相容。这里并不是在任意更改数学真理，而是在展示现有记录本身未能解决什么。

用符号简写，令 A 表示记录中的二值接受判断， T 表示参照答案。若只观察 A ，没有约束 T 的信息，就无法在 $T = A$ 和 $T = 1 - A$ 这两种可能性中作出选择；但这两种可能性给出的正确判断比例不同。这种情形叫作不可识别：针对研究问题的不同答案，仍然与已经观察到的材料相容。在只有四条记录的例子中，可能的准确率是 1/4 的整数倍，并不是零到一之间每个实数都可能。源代码分析、明确的任务参照或独立裁决，可以排除一些可能性；这里的限制针对的是所说明的观察方式。

历史标签还需要明确编码规则。如果只把“通过”记为 1，其余标签一律记为 0，测量的是记录中的接受与未接受。如果其他标签包括部分完成或结论不确定，这种编码就不会自动变成审查

者的错误指标。若只在明确通过或不通过的审查中计算准确率，应当使用不同的分母，并另外报告排除了多大比例的记录。

4.3 停止、观察资格与路径退出

4.3.1 从重建片段到实际观察路径

完整片段按第 2.5 节的高置信候选修改边连接记录；实际观察路径则是按第 2.6 节停止规则截取的部分。一步是两个送审版本之间的转移，而不是一次内部编辑、模型调用或一段固定时间。路径由保存的记录重建，同一任务可以有几条彼此分开的路径。

假设记录依次为失败、失败、通过。从第一个失败起点出发，共有两步，观察在通过时停止。因此，三份候选记录给出了两次转移。链条也可能在最新审核尚未通过时结束，这称为路径退出。任务以后仍可能在别处继续，退出因而不表示永久失败。第 7 节将按这个观察规则研究历史数据；这里先看它在简单概率模型中的后果。

模型中的成功指记录通过。未通过包括其余所有标签，也包括部分完成或未决判断；失败起点路径则必须从明确的失败标签开始。这些约定描述审核记录，而不是独立认证的题意符合性。

4.3.2 恒定条件通过概率与可预测观察

考虑反复投掷一枚正面概率为 p 的硬币，其中 $0 < p < 1$ ，直到首次正面出现。如果用正面表示记录通过，就得到一个每步通过概率恒定的连续送审模型。真实候选可能改善，审核条件也可能变化；这个说明性模型暂时把这些可能性放在一边。

为准确写出计算需要的条件，令 $j = 1, 2, \dots$ 表示一个可能的步骤。用 H_{j-1} 表示得知第 j 步结果之前已有的全部信息，例如先前候选、先前审核结果，以及已经作出的是否继续观察的决定。定义观察指示变量、接受指示变量及其累计计数：

符号	对一条路径而言的含义
B_j	如果此前没有通过，而且第 j 步将被观察，则为 1；否则为 0。
A_j	如果这一步的审核记录通过，则为 1；未通过则为 0。当 $B_j = 0$ 时也把 它记为 0，只是为了让记号完整。
$N_k = \sum_{j=1}^k B_j$	截至第 k 步实际观察到的合格步骤数。
$D_k = \sum_{j=1}^k B_j A_j$	这些步骤中记录通过的次数。由于第一次通过就停止，它至多为 1。

说 B_j 可以根据 H_{j-1} 确定，是指在看见这一步的结果之前，就能决定这条观察是否进入分析。这种性质常称为可预测的观察规则。它不是说我们能够预测下一份候选会通过。例如，“未通过就继续，已经通过就停止”只使用已有信息；“只有下一份审核看起来有希望时才保留这一行”则可能使用尚未出现的信息，不一定满足这个条件。

对于合格步骤，恒定概率假设写成

$$P(A_j = 1 \mid H_{j-1}) = p \quad \text{只要 } B_j = 1. \quad (1)$$

这要求在每一种合格过去历史之后具有相同的条件通过概率，比汇总通过比例相等更强。等价地，在合格历史上有 $E(A_j \mid H_{j-1}) = p$ 。

命题 2 (明确观察规则下的恒定条件概率)。假设在得知第 j 步结果之前就已经知道观察资格 B_j ，并且式 (1) 对每一种合格历史都成立。那么，对于每个预先固定的有限步数 k ，

$$E(D_k - pN_k) = 0, \quad \text{从而} \quad E(D_k) = pE(N_k). \quad (2)$$

进一步，如果第 1 步会被观察，并且每次未通过之后都继续观察下一步，直到第一次通过，那么首次通过的步数 T 满足

$$P(T = j) = (1 - p)^{j-1}p, \quad j = 1, 2, \dots \quad (3)$$

证明. 在合格步骤中，已知此前历史时， $A_j - p$ 的条件平均值为 $p - p = 0$ 。在不合格步骤中， $B_j(A_j - p) = 0$ 。由于观察资格已知，这两种情形都给出

$$E\{B_j(A_j - p) \mid H_{j-1}\} = 0.$$

再对可能的历史取平均，结果仍为零。对固定的步骤 $1, \dots, k$ 把这些等式相加，期望内的总和恰好是 $D_k - pN_k$ ，于是得到式 (2)。

如果每次未通过之后都继续观察，那么第一次在第 j 步通过，需要先连续 $j - 1$ 次未通过，然后通过。把每一步的条件概率相乘，得到

$$\underbrace{(1 - p) \cdots (1 - p)}_{j-1 \text{ 次未通过}} p.$$

这就是式 (3)。较早的步数通常获得更大权重，因为要到更晚才首次通过，必须先经历此前的全部未通过。这个计算使用已经声明的条件概率；在这个涵盖全部过去信息的条件之外，不需要再额外添加一个独立性假设。□

式 (3) 给出几何分布的首次通过步数 T ，它与任务符合性参照 $T(x)$ 不同。例如 $p = 0.2$ 时，第 1、2、3 步首次通过的概率分别为 0.2、 $0.8(0.2) = 0.16$ 、 $0.8^2(0.2) = 0.128$ 。尽管每一步剩下的合格路径越来越少，在这个例子中，仍然合格的路径当中下一步通过的概率始终为 0.2。因此，合格路径集合缩小，本身不能否定恒定概率模型；当然也不能据此认定历史数据符合这个模型。

4.3.3 鞅表述

早期分析有时使用“鞅”这个术语。在这里，它描述的是累计偏差

$$M_k = D_k - pN_k = \sum_{j=1}^k B_j(A_j - p).$$

已知此前信息之后，它下一步变化的平均值为零，即 $E(M_k \mid H_{k-1}) = M_{k-1}$ 。这就是这里真正需要的数学性质，上面已经证明。“过滤族”只是不断增加的信息集合的技术名称，这里用历史信息 $H_0, H_1, \dots$ 来表达。因此，鞅性质是对上面零均值增量计算的另一种表述。

4.3.4 随机分母下的平均

式 (2) 讨论的是计数的期望。它没有说 $E(D_k/N_k) = p$ ，因为实际观察的步数本身可以依赖此前的结果。一个两步硬币例子就能看清区别：取 $p = 1/2$ ，第一次通过就停止，最多观察两步。

观察到的序列	概率	D_2	N_2	D_2/N_2
通过	1/2	1	1	1
未通过、通过	1/4	1	2	1/2
未通过、未通过	1/4	0	2	0

这里 $E(D_2) = 3/4$ 、 $E(N_2) = 3/2$ ，所以 $E(D_2)/E(N_2) = 1/2$ 。但是，各条最终路径比例的平均值为 $E(D_2/N_2) = 1/2 + 1/8 = 5/8$ 。快速成功的路径只经过一次观察，就贡献一个等于 1 的比例。因此，交换“先求比例”和“先取期望”的顺序会改变答案。

如果不设步数上限、一直观察下去，用 D 和 N 表示最终停止时的全部通过次数和已观察步数；它们不同于只累计到某个固定有限步骤 k 的 D_k, N_k 。由于 $P(T > k) = (1-p)^k$ 趋于零，第一次通过会以概率 1 出现。因此，以概率 1 有 $D = 1$ 、 $N = T$ ，那个概率为零的例外不影响下面的期望。同样的区别可以写成一个精确公式：

$$E(D/N) = \sum_{j=1}^{\infty} \frac{p(1-p)^{j-1}}{j} = \frac{-p \log p}{1-p} > p.$$

把几何级数 $\sum_{r=0}^{\infty} x^r = 1/(1-x)$ 从 0 积分到 $1-p$ ，得到 $\sum_{j \geq 1} (1-p)^j/j = -\log p$ 。又因为 $0 < p < 1$ 时有 $-\log p = \int_p^1 (1/u) du > 1-p$ ，严格不等式随之成立。这是说明性模型的性质，不是本报告用于校正历史数据的公式。

4.3.5 退出与成功路径筛选

没有退出的硬币模型假设每次未通过之后都还有下一次观察。现在改成：每次未通过之后，再用第二枚独立硬币决定路径是否继续。令 a 表示继续的概率， $0 \leq a \leq 1$ 。在这个说明性构造中，所有决定继续的硬币和决定通过的硬币彼此独立。一个合格步骤之后，就有下列三种结果：

发生的事情	概率
记录通过，然后停止	p
记录未通过，然后退出路径	$(1-p)(1-a)$
记录未通过，然后继续观察下一步	$(1-p)a$

三个概率相加等于 1。把第三个概率简写为 $b = (1-p)a$ ：它表示既在当前步骤未通过，又能进入下一次观察的概率。它不是通过概率。

要在第 j 步观察到通过，前 $j-1$ 步必须每次都出现第三种结果，然后第 j 步通过。因此，

$$P(\text{退出之前在第 } j \text{ 步通过}) = b^{j-1}p.$$

不同 j 对应的首次通过事件不会同时发生。把它们的概率相加，再用 $1 + b + b^2 + \dots = 1/(1-b)$ ，得到

$$s := P(\text{退出之前通过}) = \frac{p}{1-b}. \quad (4)$$

这里 s 是关于整条路径的概率； p 是关于一个合格步骤的概率。它们的分母不同，回答的也是不同问题。

最后，假设我们删去所有未通过就退出的路径，只报告成功路径。令 J 表示这些路径记录通过的步数，使用普通的条件概率公式便有

$$P(J = j \mid \text{退出之前通过}) = \frac{pb^{j-1}}{s} = (1-b)b^{j-1}. \quad (5)$$

这又是一个几何分布，但它的参数是 $1-b = p + (1-p)(1-a)$ ；当 $a < 1$ 时，这个数大于 p 。只保留成功路径的筛选偏向较短历史：要成为一条较长的成功路径，记录必须先避开更多次退出机会。因此，看起来更快的首次通过分布，并不证明每一步通过的概率更高。

下面给出一个具体的辨识问题。考虑两种可能的机制：

机制	p	a	$b = (1 - p)a$	$s = p/(1 - b)$
甲	0.2	0.5	0.4	1/3
乙	0.5	0.8	0.4	5/6

两者在成功路径中的通过步数概率完全一样，依次为 0.6、0.24、0.096 等等。但是，它们每个合格步骤的通过概率分别为 0.2 和 0.5。只看成功路径的长度，就无法分清是哪一种机制。总体通过比例则能把它们区分开：如果同时知道 s 和 b ，式 (4) 会给出 $p = s(1 - b)$ 。这里的不确定性来自保留了哪些信息，不是概率计算本身失效。

现在可以区分三个量：合格步骤的通过率、固定路径的终态，以及筛选出的成功路径长度。若要把模型用于历史记录，还需核查它的观察假设。事后划分修改边可能用到下一候选或审核的信息，因此复现这种划分，并不能证明命题 2 要求的结果出现之前决定观察资格这一条件。后面的实证分析因而限于保留路径及其观察关联。

4.4 部分表格与逻辑约束

现在回到第 3 节的四格表。有时，我们只测量了第二个标准所对应的那一列，但仍然可以知道第一列的一些内容。例如，若一项公理政策允许的公理，是另一项政策允许公理的子集，那么，对同一个已提取声明，通过较严格的政策，就在逻辑上意味着通过较宽松的政策。这个蕴含方向必须核实，不能因为某个标准被称作“新版”，就认定它更严格。

在下面这些说明用例中，假设分数都是二值的，并且通过 R_1 意味着通过 R_0 。写成符号就是

$$q_{i1} \leq q_{i0} \quad \text{对每个候选成果 } i \in \{0, 1\}.$$

对于只取零或一的分数，这个不等式只是说：右列若是 1，左列就必须是 1；它并没有规定反方向也成立。

如果已经测得的右列是 (1, 1)，那么左列也只能是 (1, 1)。唯一允许的完整表格就是四个一，所以六个差异已经全部等于零。真正执行左列两项检查，仍然可以核验假设或者发现矛盾；但只要假设与已有观察都成立，这些差异就不可能取得另一个数值。

如果已经测得的右列反而是 (0, 0)，那么左列的两个格子都仍可以是零或一。四种允许的完整表格列在下面。用 $d = q_{10} - q_{00}$ 表示 R_0 下的候选成果差异。由于右列差异为零，按照定义可得 $I = -d$ ， $\phi_C = d/2$ 。

q_{00}	q_{10}	q_{01}	q_{11}	d	I	ϕ_C
0	0	0	0	0	0	0
0	1	0	0	1	-1	1/2
1	0	0	0	-1	1	-1/2
1	1	0	0	0	0	0

所以， d 恰好可以取 -1, 0, 1 这三个值。它的下界和上界分别是 -1 与 1，但在这个二值例子中，0.3 并不可能。同样， ϕ_C 只能取 -1/2, 0, 1/2。各个输出的取值是相互联系的：不能从一行取 $d = 1$ ，再从另一行取 $I = 1$ ，然后声称它们描述同一张表。它们必须来自同一个补全结果。

4.5 线性比较量的识别

用 $\mathcal{F}$ 表示所有允许的完整表格所构成的集合：每张表都必须符合已观察格子的值、分数允许的取值，以及已经核实的逻辑规则。用向量 $q = (q_{00}, q_{10}, q_{01}, q_{11})^\top$ 表示其中一张表。这里的 $\mathcal{F}$ 是一组可能表格，不是赋予这些表格的概率分布。暂时假设至少存在一张允许的表格。

令 $L(q)$ 表示从完整表格算出的某个比较量。本报告中的这些比较都是加权和：

$$L(q) = a_{00}q_{00} + a_{10}q_{10} + a_{01}q_{01} + a_{11}q_{11},$$

其中 $a = (a_{00}, a_{10}, a_{01}, a_{11})^\top$ 是固定权重向量，因此 $L(q) = a^\top q$ 。例如， R_0 下的候选成果差异使用权重 $(-1, 1, 0, 0)$ 。结果的单位仍然是分数点。说 L 被唯一确定，或称它点识别，就是指每一张允许的表格都给出同一个答案。

命题 3 (已有信息何时能够唯一确定一个比较量)。比较量 L 被唯一确定，当且仅当对于 $\mathcal{F}$ 中任意两张允许的表格 q 与 q' ，都有 $L(q) = L(q')$ 。对于加权和，可以通过检查下面的等式对每一对表格是否成立来判断：

$$a_{00}(q_{00} - q'_{00}) + a_{10}(q_{10} - q'_{10}) + a_{01}(q_{01} - q'_{01}) + a_{11}(q_{11} - q'_{11}) = 0.$$

进一步取得的有效证据，只能排除原来允许的表格。只要仍至少剩下一张表，可能答案的最大下界就不会下降，最小上界就不会上升。当可能答案构成有限列表时，这两个界限就是列表中的最小值与最大值。

证明。如果两张允许的表给出不同答案，那么现有观察与规则同时容许这两个答案，因而答案不唯一。如果每张允许的表都给出同一个答案，这个答案就由现有信息确定了。对加权和而言，用 $L(q)$ 减去 $L(q')$ ，恰好得到上面展示的式子。最后，从一个列表中删去若干选项，不可能产生一个比原最小值更小、或者比原最大值更大的新值。如果允许的分数的构成无限集合，同一道理应当用最大下界和最小上界表述。□

在刚才的四行例子中，若进一步观察到 $q_{00} = 0$ ，就排除最后两行， d 的可能取值从 $\{-1, 0, 1\}$ 缩小为 $\{0, 1\}$ 。若还观察到 $q_{10} = 1$ ，就只剩第二行，并确定 $d = 1$ 。这才是增加了信息。相反，在原来的每一行中计算 $\phi_C = d/2$ ，不会排除任何一行。一个有用的摘要，并不一定是一项新观察。两要素分摊可以帮助解释已有材料，却不能补上缺失的格子或缺失的任务参照。

如果测量与声称成立的规则互相矛盾，就可能没有任何允许的表格。例如，一方面声称“两个标准对某候选成果总给出相同分数”，另一方面又测得该候选成果的两个分数分别是 0 和 1，二者就冲突了。这时应报告不一致，而不是编造一个补全结果。发布包中的一致性防护会拒绝这一类具体矛盾。同样，无效或不适用的比较，也必须先解决其含义问题，才能讨论可能的数值。

对于含义成立、但分数未知的格子，发布的数值核心允许它在 0 与 1 之间取值，并使用每格单独给出的取值区间来计算界限。计算时允许从各格区间中分别取值并任意组合，没有表达格与格之间的约束。这里逐格允许组合的计算方式，不是假设随机变量在概率意义下相互独立。这些界限描述缺失信息带来的不确定性，不是统计置信区间。如果分数实际上只能是零或一，真正能够达到的结果就可能像上例那样是离散的。如果格子之间还存在其他关系，逐格区间也可能允许实际上不可能的组合，从而给出偏宽的界限。基线代码支持一些特定的相等关系与二值蕴含推断，但并未实现能处理任意 $\mathcal{F}$ 的通用求解器。这条命题解释的是推理原则，不是在声称软件已经拥有尚未实现的能力。

这也解释了历史比较中的一个区别：在已经通过的那些案例里，已核实的政策蕴含关系已经确定了尚未测量的政策格子；其他取值结构则可能从额外测量中获益。六个指定诊断量在加入分摊前后具有相同的可回答程度，并不能证明分摊在任何地方都无用。它反映的是这些具体问题需要哪些信息。

5 可执行检查究竟确认了什么

现在将这些区别用于第 2.7 节的 14 对选定候选，以及第 2.8 节另行介绍的构造材料。编译与公理检查确认形式文件的一些性质；定义反例和布尔对照则进一步检验，这些性质是否足以保证完成原任务。

5.1 编译、目标提取、公理与题意

一个 Lean 文件可以包含多个有名称的定义和定理。指定目标是评价前选定的声明。同一文件中的另一条定理证明成功，不能替代对这个目标的检查。

需要区分四个问题。第一，文件能否在记录的软件环境中通过编译？这会检查语法、名称、类型及所提供的证明在该环境中是否被接受。第二，能否找到并提取指定目标？第三，这个声明依赖哪些公理？公理是作为推理起点接受的命题；Lean 不仅能报告直接依赖，还能追踪经由其他定义和定理形成的依赖。第四，这个被接受的声明是否表达并满足任务原本要求的数学内容？前三项为第四项提供证据，却不能单独决定答案。特别是，内核检查的是实际写出的形式命题是否具有相对于其定义和假设的有效证明；这个命题与任务原意是否一致，还需要另行解释和核对 [1, 2]。

历史候选执行采用 Lean 4.31.0，每个候选最多运行 240 秒，同时最多运行两个进程。实验使用两套公理政策。第一套排除 `sorryAx`，它是与未完成证明的占位写法相关的依赖；这种写法允许文件保留一个尚未补齐的证明。第二套只允许 `propext`、`Classical.choice` 和 `Quot.sound` 这三个列明的基础公理。通过某套政策，只说明满足了相应的公理依赖规则，并不说明定理的假设符合任务要求，也不说明定义采用了任务指定的约定。这两套政策是实验检查，不能当作完整历史审查要求的新旧版本。

28 个历史候选版本全部尝试了执行：17 个编译成功，11 个失败，没有超时。17 个成功文件中，16 个能够提取预先指定的目标，并且这 16 个目标全部通过两套公理政策。另一个成功文件 `ex_3_1_2/from` 缺少指定声明，核查没有在看到结果后改选一个方便通过的目标。因此，只有六对候选拥有完整的四格公理评价表，且各表四格均为一。这些结果描述的是本次记录的当前环境。原历史环境的完整依赖没有重建，因此当前编译失败不能证明文件在原历史环境中也曾失败。

5.2 针对直接假设结论的狭窄检查

一个形式上有效的证明，可能证明了比原任务更弱的命题。用初等例子说明：假设任务要求证明，对每个实数 x 都有 $x^2 \geq 0$ 。如果改写成“若 $x^2 \geq 0$ ，则 $x^2 \geq 0$ ”，证明就很容易，因为假设已经给出了结论。这个条件命题在逻辑上成立，却没有证明原任务要求的无条件结论。这只是帮助理解的说明例，不是一条新增的历史观察。

另一条要求检查，正是询问主定理是否把它的完整结论直接列为公开假设。此项检查由单个人工智能评估者完成。它不能发现所有弱化命题的方式，也不能发现所有间接把证明负担移入假设的方式；本研究没有独立专家给出的参考判定。14 对候选为本项要求评估提供 $14 \times 4 = 56$ 个评价单元，其中 27 个可测量，23 个不适用，四个不确定，两个无效；只有六张表完整且可比较。“不适用”表示这个特定检查不适合该对象；“不确定”表示证据不能给出确定判断；“无效”表示拟议评价不能按所声明的方式使用。它们都没有被悄悄换算成一次测得的失败。这些数量说明哪里可以完成测量，不说明历史数学内容有多大比例正确。

5.3 四种评价方法与诊断可答性

对一对候选和两套要求，每张表提出六个诊断问题：分别在两套要求下，更换候选有什么变化；分别对两个候选，更换要求有什么变化；候选与要求同时更换时总共有何变化；以及候选变化的表现是否随所用要求而改变。最后一个问题，就是前面数学框架介绍的交互项。

四种方法的区别在于允许使用的信息。历史标签使用保存的审查判断；若不能把原评价器与本次评价器视为同一个，就暂不给出答案。固定 R_1 用第二套要求检查两个候选，其中 R_1 是第二套要求的记号。四格使用两个候选与两套要求的全部四种组合。四格加夏普利分配使用同样的观察，再按照前文介绍的办法，对两种更换顺序取平均，从而分配对角总变化。

固定要求的方法同样可以使用已核实的有效规则相同信息，以及成立的逻辑蕴含。例如，通过更严格的公理允许清单必然意味着通过更宽松的清单，那么一次严格政策的通过结果，就足以推出宽松政策也通过，无须再次执行。这种格子被记录为逻辑推导。如果刻意不向简单方法提供这条信息，就会不公平地夸大四格方法的信息优势。

表 4: 六个诊断问题中，能够给出有依据的单一数值答案的数量。“可答位置”是同一行所有方法共同使用的分母。

证据组	可答位置	历史标签	固定 R_1	四格	加夏普利
构造例子（7 个）	42	4	17	26	26
公理：开发组（6 对）	36	0	13	13	13
公理：留出组（8 对）	48	0	27	27	27
要求：开发组（6 对）	36	0	12	12	12
要求：留出组（8 对）	48	0	25	25	25

例如，第一行包含七张构造表，每张提出六个问题，因此有 $7 \times 6 = 42$ 个可能的答案位置。四格方法能够回答其中的 26 个问题；这不是对 42 个独立抽样任务作出了 26 次正确判断。开发组的每行使用六对历史候选，所以分母为 $6 \times 6 = 36$ ；留出组的每行使用八对，因此分母为 $8 \times 6 = 48$ 。公理检查和要求检查重复使用同一批历史候选对，不能把这些位置当成独立样本。历史标签列中的零，表示另一评价器保存的标签不能提供这里规定的当前测量，并不表示所有历史标签都是错的。

在构造例子中，四格方法比固定 R_1 多回答九个问题；在各历史组中没有增加可答问题。夏普利分配没有增加可回答的问题，因为它没有增加新的观察。构造表另有 26 个可核对、预先手写的参考答案，没有发现实现结果与之不一致。这些参考答案用于检查设计案例的算术，不是经独立裁决的历史语义正确性基准。历史组中差值全为零应怎样作统计解释，将在本报告的统计部分另行讨论。

5.4 为什么空集能区分两个定义

考虑历史任务 `def_2_1`。两个集合之间的双射，就是把双方元素一一配对，每个元素都恰好有一个配对对象，既不遗漏，也不重复。自然数集 $\mathbb{N} = \{0, 1, 2, \dots\}$ 有无限多个元素。有限集合不能与全部自然数一一配对。特别地，空集 $\emptyset$ 没有任何元素，连自然数 0 所需要的配对对象都无法提供。

“可数”有两种常见约定。一种把有限集合以及能与自然数集建立双射的集合都包括在内；另一种专指能与自然数集建立双射的集合。保留的两版任务文字都使用第二种约定。较早的候选却采用 Lean 中的 `A.Countable`，把有限集合也包括进来。较新的候选使用了任务要求的双射约

定，并另外命名了范围更广的“至多可数”概念。因此，问题在于是否忠实遵守本任务的约定，并不是说较宽的约定通常就是错误的。

核查所用的参考谓词是：“存在从 A 到整个自然数集的双射。”这里的 A 是输入给这个定义的集合；谓词就是对一个对象提出的真假断言。为便于查阅实现，这条参考断言在 Lean 中写成

$$\text{Nonempty}(A \simeq (\text{Set.univ} : \text{Set } \mathbb{N})).$$

符号 $\simeq$ 表示要求一个双射；`Set.univ` 表示指定类型的全部元素组成的集合，这里就是整个自然数集；`Nonempty` 断言至少存在一个这样的双射。它不是仅仅断言 A 中有元素。把任务的自然语言翻译成这条形式参考，仍然是本次核查中由人工智能作出、可以公开检查的解释，没有独立专家参考；不能只凭编译通过就认为这一步解释已经得到认证。

空集现在就给出了完整的反例论证。旧定义接纳空集，因为其约定包括有限集合。参考定义拒绝空集，因为任何双射都必须让 0 在空集中找到一个原像，而空集中没有元素。新定义也因同样的理由拒绝空集。只需一个反例，就足以推翻“两个谓词对所有集合都给出相同答案”的断言。

见证文件把两版候选的主体保留在不同命名空间，共用原有的 Mathlib 导入，然后补入六条已证明的命题：旧谓词接纳空集；参考谓词拒绝空集；新谓词拒绝空集；新谓词对所有集合都与参考谓词一致；旧谓词并非对所有集合都与参考一致；以及新旧谓词确实不同。新谓词与参考的一致性可通过展开定义得到。这六条命题共同描述一个被调查的案例，不能当作六次独立的语义核查成功。

成功编译的退出码为零，用时 217.685 秒。两版候选定义打印出的公理集合都为空；四条见证命题只依赖 `Quot.sound`，另两条的公理集合为空。来源与消息验证器通过了 23 项检查。此前一次因 Windows 路径过长引起的启动失败发生在编译之前，仍保留在档案中；成功运行使用了较短目录。这些证据确认的是相对于所选参考的这一项数学差异，不是对整个修改后文件或全部下游定理的认证。

5.5 对一个布尔任务穷尽行为检查

有限域挑战不要求读者理解高等数学。任务有两个布尔输入，每个输入只能取假或真；当且仅当恰好一个输入为真时，函数必须返回真。输入组合总共只有 $2 \times 2 = 4$ 种，因此表 5 可以完整列出所有要求。参考表在执行之前就已固定。

表 5: 双输入任务的完整参考真值表。

第一个输入	第二个输入	要求输出	理由
假	假	假	没有输入为真。
假	真	真	只有第二个输入为真。
真	假	真	只有第一个输入为真。
真	真	假	两个输入都为真，不是恰好一个为真。

实验有意设计了九种实现：三种正确写法、五种具有相同函数类型的错误写法，以及一种编译失败的对照。函数类型只规定“接受两个布尔值，返回一个布尔值”，说明允许输入和输出哪类值，却不说明某个具体输入应该返回哪个值。因此，“永远返回假”的函数可以与正确的异或函数拥有相同类型。

表 6 将每种可执行实现与全部四行参考逐一比较。例如，析取只在两个输入都为真时出错：它返回真，而任务要求假。因此，穷尽执行区分出了三种一致实现和五种不一致实现；无法执行的版本仍记为不确定。通过前两种检查不足以确认为符合任务。由于九种实现是围绕同一个

表 6: 有限任务保存的观察结果。八种可执行实现均通过公理检查和打印类型检查。横线表示没有可用的执行证据。

编号	实现	不匹配输入数	行为结果
01	异或	0/4	一致
02	布尔值不相等比较	0/4	一致
03	用条件分支实现异或	0/4	一致
04	合取：两个输入都为真	3/4	不一致
05	析取：至少一个输入为真	1/4	不一致
06	经辅助函数实现相等比较	4/4	不一致
07	恒定返回假	2/4	不一致
08	只返回第一个输入	2/4	不一致
09	调用未定义的函数	—	不确定

任务有意设计的，“八个中有五个”不能解释为某个总体的误接纳率，也不能视为八个独立抽样任务的证据。按具体能力组织行为测试已有方法上的先例 [5]，但这里没有照搬该研究在自然语言处理中的性能结论。有限输入上的执行检查，也不同于上一个定义例中由内核检查的数学命题证明。

原评价器将每种实现与一个固定的正确基线分别编译，共有 18 次候选编译；另有九次行为探针编译，合计 27 次尝试。重复编译的基线属于测试安排，不会增加独立证据。一个单独的验证器从保存的标准输出重建观察，不调用原来的评分计算。它在修正换行规范化缺陷后通过了 166 项检查：最初九个测试文件的哈希失败来自 LF 与 CRLF 换行差异。两版验证器和首次失败报告均已保留。规范化仅用于测试文件的换行，实际执行源码和探针的哈希仍要求完全一致。没有通过重新做实验来替换那次失败的验证记录。

5.6 结果重建与矛盾输入的拒绝

排除运行耗时之后，保存的 35 张比较表均被精确重建。早期重建测试集通过 52 项测试；其来源与数量核对验证器，对读取的 227 份来源快照通过了 6,093 项检查。这些结果检验的是既定实现规则下的可复现性，不是独立的语义正确性。

核查还发现了一个输入一致性问题。假设输入声称，新候选在两列面对完全相同的有效要求，但实测格子却是 $q_{10} = 0$ 、 $q_{11} = 1$ 。这里，第一格是新候选在第一套要求下的结果，第二格是它在第二套要求下的结果。对同一候选执行相同的确定性检查，不应同时得到拒绝与接纳。旧基线可能根据“要求相同”的声明推得要求变化为零，而直接相减却得到 $1 - 0 = 1$ 。便携实现现在会在写出结果之前拒绝这种矛盾输入，不再把两个互相冲突的答案都呈现为有效结果。

该实现的 50 项单元与回归测试，和先前的 52 项重建测试是两套不同测试。本报告保留这一实现及其 35 个兼容性案例。本轮写作修订改变的是说明方式，没有改变已有实验、实验结果或生产形式化语料。

6 记录判断的配对统计

6.1 结果定义：记录通过

沿着选定的候选修改，较晚端点记录通过的频率比早期端点增加了多少？较大的历史档案允许我们把相应的前后记录配对，计算这一变化。

本节使用按第 2.4 节活动规则选出的全部 465 条候选修改边，涉及 250 个任务；配对分析不在首次通过处停止。每条边比较同一作业题的两个版本，一个任务可以贡献多次比较。因此，前后记录是配对观察，而任务是归组重复观察的单位。

先将记录标签转换成数值结果。记录写明 `pass`，即通过时，记为 $A = 1$ 。对于明确记录为 `fail`、`inconclusive`、`partial`，即失败、无法定论、部分完成的情形，记为 $A = 0$ 。因此， A 只回答“是否记录了通过”。零不表示数学内容一定错误；尤其是无法定论的审查，并未认定数学失败。分析脚本会拒绝缺失或无法识别的标签，而不是悄悄将其补成零。表 10 还保留了原来的四个类别。

对一条边，用较晚值减去较早值。 $0 \rightarrow 1$ 贡献 $+1$ ， $1 \rightarrow 0$ 贡献 -1 ，两端二元值相同则贡献 0。这些量都没有直接衡量语义正确性；所计算的结果始终是记录中的审查决定。

6.2 任务等权与边等权平均变化

考虑表 7 中的说明性例子。任务甲在一次选定修改后通过，任务乙直到第三次才通过。两个任务最终都通过了，但记录的边数不同。

表 7: 仅用于说明的例子：不同任务贡献的边数可以不同。表中数值表示是否记录通过，不是数学质量分数。

任务	边数	较早值 $\rightarrow$ 较晚值	边差值的平均数
甲	1	$0 \rightarrow 1$	1
乙	3	$0 \rightarrow 0$ 、 $0 \rightarrow 0$ 、 $0 \rightarrow 1$	$1/3$

若每个任务只占一份权重，平均数是 $(1 + 1/3)/2 = 2/3$ 。若每条边各占一份权重，平均数是 $(1 + 0 + 0 + 1)/4 = 1/2$ 。两者不同，是因为后一种算法给予任务乙的权重是任务甲的三倍。两种算术运算都没有错；它们分别回答“各任务自身的平均变化，再按任务平均是多少”和“所有已记录边的平均变化是多少”。它们都不是最终通过的任务比例；在这个例子中，最终通过比例是 $2/2$ 。

现在为实际数据中的这些对象逐一命名。用 S 表示纳入的任务数，主分析中 $S = 250$ 。下标 k 表示任务编号，从 1 到 S ； n_k 是任务 k 的选定边数。在任务 k 内，下标 e 从 1 到 n_k ，用于标记其中的边。 $A_{ke,0}$ 和 $A_{ke,1}$ 分别表示这条边的较早和较晚二元值。定义

$$d_k = \frac{1}{n_k} \sum_{e=1}^{n_k} (A_{ke,1} - A_{ke,0}), \quad (6)$$

$$\hat{\mu}_{\text{task}} = \frac{1}{S} \sum_{k=1}^S d_k, \quad \hat{\mu}_{\text{edge}} = \frac{\sum_{k=1}^S n_k d_k}{\sum_{k=1}^S n_k}.$$

其中， d_k 是一个任务内部的平均边差值， $\hat{\mu}_{\text{task}}$ 是任务等权平均数， $\hat{\mu}_{\text{edge}}$ 是边等权平均数。这三个量都是零到一尺度上的无量纲差值，乘以 100 才是百分点。 d_k 也等于该任务的较晚端点均值减去较早端点均值；后面的统计计算，配对的正是每个任务的这两个均值。

在完整保留集合中，较早端点出现 118 次通过，较晚端点出现 328 次通过。因此

$$\hat{\mu}_{\text{edge}} = \frac{328 - 118}{465} = \frac{210}{465} \approx 0.451613,$$

即增加 45.16 个百分点。若先算每个任务的差值，再对 250 个任务平均，则得到 $\hat{\mu}_{\text{task}} = 0.570909$ ，即增加 57.09 个百分点。在引入任何概率模型之前，这两个数就已经是对指定档案与纳入规则的精确描述；展示的小数经过了舍入。

6.3 为什么 465 条边不是 465 个独立观察

考虑记录值为 $0 \rightarrow 0 \rightarrow 1$ 的一条链。两个相邻差值共用了中间记录：它既是前一条边的较晚端点，也是后一条边的较早端点。更一般地，若一条链有 m 条边，各端点数值依次为 $a_0, a_1, \dots, a_m$ ，则

$$(a_1 - a_0) + (a_2 - a_1) + \dots + (a_m - a_{m-1}) = a_m - a_0.$$

所有中间值都互相抵消。因此，一条长链可以提供很多行数据，却不一定提供同样多的独立净变化观测。

保留的图中有 930 次端点出现，但只有 783 条不同的端点记录；其中 147 条记录出现在两条边中。其 318 条极大链使用全部 465 条边构成，与 367 条高置信边所组成的 262 个过程片段不同；这些链满足上述抵消恒等式，总净差值为 210。共同的任务难度、反馈和审查条件还可能带来额外依赖。103 个任务具有多条边，单个任务最多有 26 条边；边数最多的五个任务占全部边的 14.41%。这里的图链仅用于诊断这批边的结构，并未替换后文失败起点过程的定义。

所以，我们先将每个任务概括为配对差值 d_k ，再计算 t 统计量；计算参考区间时也以整个任务为单位重抽样。这样保留了任务内部的依赖结构，但不能证明不同任务彼此独立：它们仍可能共用审查者、批次、数学依赖或不断变化的规则。

6.4 配对 t 计算及其参照假设

6.4.1 平均差与标准误

本次有条件计算使用 250 个任务层面的配对差值，参照模型要求任务独立，并遵循同一种记录选择机制。

令 D 为参照总体中的任务差值，均值为 $\mu_D = E(D)$ ，标准差为 σ_d 。对于观察到的 $d_1, \dots, d_S$ ，

$$s_d = \sqrt{\frac{1}{S-1} \sum_{k=1}^S (d_k - \hat{\mu}_{\text{task}})^2}.$$

观察样本的标准差为 $s_d = 0.430341$ ，即 43.03 个百分点。

在任务差值相互独立、共同方差为 σ_d^2 的条件下，

$$\text{Var}\left(\frac{1}{S} \sum_{k=1}^S D_k\right) = \frac{1}{S^2} \sum_{k=1}^S \sigma_d^2 = \frac{\sigma_d^2}{S}.$$

估计标准误为

$$\widehat{\text{SE}} = \frac{s_d}{\sqrt{S}} \approx \frac{0.430341}{\sqrt{250}} \approx 0.027217.$$

在该任务模型下，它是 2.72 个百分点。跨任务依赖会引入协方差项，因此直接除以 $\sqrt{250}$ 未必能描述实际档案中均值的不确定性。

6.4.2 零假设与观察统计量

配对零假设为指定任务总体中的 $H_0: \mu_D = 0$ 。保存的双侧计算为 [4, 7]

$$t_{\text{obs}} = \frac{\hat{\mu}_{\text{task}} - 0}{s_d / \sqrt{S}} \approx \frac{0.5709091575}{0.0272171622} \approx 20.9761. \quad (7)$$

配对的两项是每个任务的较晚端点均值和同一任务的较早端点均值。把前后集合当成独立样本会丢掉这层配对；本节的模型针对的是两者之差。

6.4.3 参照分布与适用范围

对于独立同分布、具有正方差的正态任务差值，零假设下的参照分布为自由度 $S - 1 = 249$ 的 t 分布。

实际任务差值有上下界，而且只取离散值，因此并不严格满足正态差值模型。对于这 250 个任务，报告仅在额外的独立任务模型下，将 Student t 计算用作探索性的大样本参照。尤其需要注意，任务数量较大，既不能认证任务独立性，也不能保证极小尾概率的数值校准准确。

令 $Z \sim t_{249}$ ，名义双侧 p 值为

$$p_{\text{ref}} = \Pr\{|Z| \geq |20.9761|\} \approx 5.87 \times 10^{-57}.$$

这是参照模型下的名义尾概率；该模型是否适用于这批选定档案尚未得到确认。数值很小并不能建立数学改善。

6.5 任务整群重抽样与参考区间

为了考察所含任务构成的变化，保存的分析采用以整个任务为抽样群的自助法 [6]，每次抽取都携带该任务全部选定配对边。

每次重复，都从已有的 S 个任务编号中，等概率、独立地抽取 S 次。被抽中的任务会带上全部边和每条边的两个端点。任务等权均值由抽中任务的差值重新平均。边等权均值则用抽中任务的总净变化除以总边数，所以其分母在不同重复之间可能变化。

保存的分析执行了 20,000 次重复。将所得数值排序，取第 2.5 和第 97.5 百分位数，得到报告中的中央 95% 百分位区间。完整数据的任务等权区间为 $[0.518357, 0.624482]$ ，即 $[51.84, 62.45]$ 个百分点；边等权区间为 $[38.63, 52.12]$ 个百分点。复算使用 NumPy PCG64、种子序列 $[20260906, r]$ 和线性百分位插值，其中 $r = 0, 1, 2$ 标记三条分析路线。

这里称为参考区间，是因为通常的 95% 覆盖率解释需要任务彼此独立、足够可比，并由同一种历史及纳入机制产生。这批回顾性档案尚未确认这些假设。给定 250 个观察差值，均值 0.570909 就是固定的；区间描述的是假想任务构成变化。按整任务重抽样保留了任务内部依赖，但不能修复选择偏差、跨任务依赖或缺少语义结果测量的问题。

这与逻辑补全界不同。例如，设较早分数为零，较晚分数尚未测量，但只能是零或一。差值便可能为零或一，紧确界为 $[0, 1]$ 。这些可能性没有指定概率，也不带有 95% 覆盖率的含义；测得缺失分数后，歧义就可能消失。任务自助法则使用已知分数，改变假想样本的构成。

6.6 三种选取规则下的结果

表 8 和表 9 列出主分析及两条敏感性路线。敏感性路线改变某项纳入规则，展示这个变化后的问题会得到什么答案。三条路线是在上一版修订期间、数值估计之前声明的，但当时已经了解这批档案，因此这是回顾性探索，不是前瞻预注册。三项未经多重比较校正的双侧参考检验均予报告；没有按 p 值大小择取路线，逐项区间也不提供三条路线同时成立的置信保证。

完整集合中，182 个任务的差值为正，67 个为零，1 个为负。数据中确实存在变化，因此标准差非零， t 统计量可以计算。任务等权与边等权均值之间的差距也有实际意义：选定历史较长的任务在第二种均值中权重更大，而它们合起来的每边净变化较小。

四分类表解释了编码为什么重要。25 条边至少有一端为无法定论或部分完成；其中 17 条从这种结果转为通过，1 条从通过转为这种结果。因此主均值还包含了“是否记录了明确通过”的变

表 8: 记录通过的变化, 单位为百分点。方括号内为以任务模型为前提的 95% 任务整群百分位参考区间。改变路线, 也改变了纳入的边和任务。

路线	边数 / 任务数	任务等权变化	边等权变化
全部候选修改边	465 / 250	57.09 [51.84, 62.45]	45.16 [38.63, 52.12]
两端均为通过或失败	440 / 236	55.73 [50.15, 61.21]	44.09 [37.36, 51.18]
高置信候选修改边	367 / 207	76.93 [71.89, 81.73]	59.95 [50.44, 70.10]

表 9: 对任务层面均值进行的配对计算。前后百分比均为任务等权。名义 p 值使用尚未验证的 Student 参照模型, 不检验语义改善。

路线	较早 → 较晚	t (df)	双侧 p_{ref}
全部候选修改边	29.16% → 86.25%	20.9761 (249)	5.87×10^{-57}
两端均为通过或失败	31.59% → 87.32%	19.7176 (235)	1.00×10^{-51}
高置信候选修改边	6.92% → 83.85%	30.5239 (206)	2.21×10^{-78}

化。限制两端都只能为通过或失败, 会去掉这些边, 但也改变纳入的任务。这是另一个经过选择的目标, 而不是给原样本换了一个更好的名字。

高置信路线沿用的是候选修改边的置信分类; “高置信”不是数学修复已获独立认证。该分类规则使用此前的结构化问题记录。在主估计之后增加的一项描述检查显示, 两组的起点构成差异很大: 高置信子集在 367 条边中有 21 个较早通过端点; 与之互补的 98 条中置信边, 开始时有 97 个通过, 结束时有 87 个。这个互补集合涉及 81 个任务, 任务等权变化为 -11.73 个百分点, 边等权变化为 -10.20 个百分点。本项估计后检查没有附加新的检验或区间。起点几乎全部通过的组, 向上增长的空间很小; 起点大多未通过的组, 空间则大得多。因此, 高置信组变化更大, 并不能证明其修改更有效。

其他解释也没有排除。45 条边的来源审查契约字段不同, 2 条边的任务内容字段不同; 字段一致并不证明实际审查条件完全相同。在 783 条不同端点记录中, 781 条的检查范围未知, 1 条明确报告未审查, 1 条报告存在可审查性阻碍。本次投影没有检查独立执行。451 条边处于单独案例评估之外, 因此较大统计集合中的这些边缺少对应语义评估。候选本身改善、评估条件变化和选择性继续, 都可能带来记录标签变化。向均值回归也可能带来部分变化。没有合适的比较设计和独立语义结果, 仅凭很小的 p 值无法区分这些解释。

6.7 为什么零诊断差值给出未定义的 t 统计量

较小的评价器比较测量另一种结果: 预先规定的诊断问题中, 能够给出确定答案的数量。四格方法的基线在 R_1 下检查两个候选, 同时使用已经核实的标准关系; 由这些关系得到的推论, 也属于基线可用的信息。

表 10: 全部 465 条边的原始审查标签。行表示较早端点, 列表示较晚端点。即使“无法定论”和“部分完成”都没有编码为通过, 它们仍在表中单独呈现。

较早 / 较晚	通过	失败	无法定论	部分完成
通过	105	12	1	0
失败	206	117	5	1
无法定论	16	0	1	0
部分完成	1	0	0	0

对任务 k ，令 $C_{k,4}$ 为四格方法给出的确定答案数， $C_{k,F}$ 为固定要求基线的相应答案数。每个计数介于零和六之间。定义 $D_k = C_{k,4} - C_{k,F}$ ，其单位是诊断问题数，不是百分点。在两种历史评估中，各自的 14 个 D_k 都是零，而且逐个答案也一致。套入相同计算步骤，得到

$$\bar{D} = 0, \quad s_D = \sqrt{\frac{1}{13} \sum_{k=1}^{14} (D_k - \bar{D})^2} = 0, \quad t_{\text{obs}} = \frac{0}{0/\sqrt{14}} = \frac{0}{0}.$$

该统计量未定义，并非得到 $t = 0, p = 1$ 的 t 检验。前面的 250 任务计算中存在非零变化，分母可以定义；这里没有。

精确的描述性发现仍然有用：对于这些选定历史案例，两种方法给出的答案相同。但任务自助法只能重新抽出一串零，符号方向比较也没有正差或负差可比较。这些计算不能揭示未观察任务是否会出现差异。将相同 14 个任务重复用于两种评估，或分别数它们的六个问题和四个格子，都不能制造独立任务信息。若要声称总体等效，需要明确总体、合理的不确定性模型，并事先说明等效问题中多大的差异在实际意义上可以接受。

七个构造例子相对固定基线的增益为 $[5, 0, 4, 0, 0, 0, 0]$ 。它们证明额外信息可能有帮助：刻意安排的样例构成，不能估计这种帮助在普通任务中有多常见。夏普利分配相对直接读取四格，在全部 35 张表中都没有增加诊断可答性，这与它使用相同观测信息一致。这些是不同的比较，不应混成“所有地方的增益都为零”这一说法。

6.8 八对编译结果：精确 McNemar 检验

八个任务隔离留出候选对还支持另一项可计算的比较：较早与较晚候选在当前测试环境中是否能够编译？表 11 给出完整配对观察。这一结果只涉及编译，不表示预期数学命题已经得到正确表达。

表 11: 八个留出任务对的实际编译结果。提供变化方向信息的是两个非对角单元格，而不是将 16 个端点分开后视为独立观测。

较早 / 较晚	编译失败	编译通过	合计
编译失败	1	1	2
编译通过	1	5	6
合计	2	6	8

五对两端均能编译，一对两端均不能；一对从失败转为成功，一对从成功转为失败。因此，前后均为八个候选中六个编译通过，配对净差为 $(1 - 1)/8 = 0$ 。改善的是任务 `def_13_2`，退步的是任务 `prob_10_1`。

精确 McNemar 计算所问的是：不一致配对的方向是否平衡 [3]？令 $b = 1$ 记录失败转成功的对数， $c = 1$ 记录反方向的对数，则不一致配对总数为 $m = b + c = 2$ 。在不同不一致方向相互独立、两种方向等概率的条件零假设下，假想重复中改善方向的个数 B 服从试验次数为 $m = 2$ 、成功概率为 $1/2$ 的二项分布。采用较小尾概率的两倍、最多截为一的双侧规则，得到

$$p = \min\{1, 2\Pr(B \leq 1)\} = \min\{1, 2(1/4 + 1/2)\} = 1.$$

这个 p 值确实有定义，但只有两个提供信息的方向。它没有给出反对上述零假设的方向性证据；也没有证明编译概率等效、修改没有效果或语义正确。留出选择经过分层且具有回顾性，任务隔离本身不能证明统计独立，也不能抹去先前暴露。这项检验只是适用于配对二元数据的一次有限计算示例，不能代替较大集合的任务层面分析。

配对差概括了选定修改的变化。若要研究这些变化的先后顺序，就需要沿路径逐步观察，直到首次记录通过或路径退出。

7 沿固定失败起点路径观察

7.1 固定分析集合、首次通过停止与退出

现在回到第 2.5 节和第 2.6 节定义的高置信重建：367 条边形成 262 个完整连续片段，从中选取起点明确失败的 230 个片段，得到涉及 182 个任务的固定分析集合。选取起点与在首次通过处停止观察是两项操作；不会仅因为后来的记录属于同一任务，就把它接入原路径。

按照第 4.3 节的定义，第 1 步是从失败起点到另一送审候选的第一次合格转移，其结果是后一个候选获得的审核标签。随后每一步也都是这样的一次送审版本转移。路径在第一次记录通过或允许的链条结束时停止，以先发生者为准。230 条路径总共贡献 329 个实际观察的步骤。每个步骤及其结果构成一条合格步骤记录，传统上也称为风险行。“处于风险中”在这里仅指仍有资格记录首次通过。

这里有两种终态。206 条路径在链条结束之前记录通过，另外 24 条到达链条边界时尚未出现这种通过。针对本节的问题，退出是已经观察到的终态，不是把某个未知结果悄悄填成“不通过”。它描述的是这条分析路径在哪里结束，不证明任务被放弃、不证明未来候选都会失败，也不说明应该把别处的最终通过添加到原路径。

如果问题变了，对退出的处理也会变。如果我们问的是“同一种机制假如一直运行下去，这个任务还要多久才通过”，退出之后的结果就是未观察的。把这样的记录称为删失，并不会让缺失的后续结果变得已知；还需要额外假设，把假想的持续过程与已观察路径联系起来。本报告不估计这种假想等待时间。

7.2 逐步计数、风险集与累计比例

第 1 步，全部 230 条失败起点路径都具有观察资格。其中 167 条通过，18 条尚未通过就结束，45 条继续进入第 2 步：

$$230 = 167 + 18 + 45.$$

第 2 步，只剩下这 45 条继续的路径。其中 29 条通过，4 条退出，12 条继续：

$$45 = 29 + 4 + 12.$$

第二个分母是 45，因为此时所问的是到达第 2 步的路径。它不是又抽取了 230 条路径，也不是把全部任务多修改一次之前和之后作比较。表 12 把同样的计数一直列到最后一个已观察步骤。

为了给所有步骤统一记号，令 n_j 表示第 j 步的合格路径数， d_j 表示这一步通过的路径数， c_j 表示这一步未通过后退出的路径数。于是，

$$n_j = d_j + c_j + n_{j+1}. \quad (8)$$

这是计数恒等式，不是拟合得到的模型。组成 n_j 的那一组路径，叫作第 j 步的风险集。它的缩小可由记录通过数和退出数解释，不需要先假设通过概率恒定。

另外两个有用的累计量始终使用起初的分母 230：

$$F_P(j) = \frac{d_1 + \cdots + d_j}{230}, \quad F_X(j) = \frac{c_1 + \cdots + c_j}{230}. \quad (9)$$

表 12: 固定的 230 条路径。每一行把到达该步骤的路径分为通过、退出或继续，三类互不重叠。

步骤	合格路径	通过	退出	继续
1	230	167	18	45
2	45	29	4	12
3	12	1	0	11
4	11	5	0	6
5	6	2	1	3
6	3	0	0	3
7	3	0	0	3
8	3	0	0	3
9	3	0	0	3
10	3	0	0	3
11	3	1	0	2
12	2	1	0	1
13	1	0	0	1
14	1	0	0	1
15	1	0	0	1
16	1	0	0	1
17	1	0	1	0
各步骤相加	329	206	24	—

$F_P(j)$ 表示原始路径中截至第 j 步已经通过的比例； $F_X(j)$ 表示截至这一步尚未通过就退出的比例。下标 P 对应通过， X 对应退出。它们是累计比例，也称累计发生比例。剩余比例为 $n_{j+1}/230$ ，所以这三个比例相加等于 1。在最后一个已观察步骤，

$$F_P(17) = 206/230 = 89.57\%, \quad F_X(17) = 24/230 = 10.43\%.$$

由于退出本来就是两种记录终态之一，计算这些有限路径的比例，不需要假设退出与未来成功彼此独立。

把一条路径直到通过或退出为止的合格转移次数，叫作它的已观察长度。全部长度加起来为 329，因此平均长度为 $329/230 = 1.4304$ 次转移。短路径既可能很快通过，也可能很快退出；这个数字不是最终成功所需编辑次数的平均值。

7.3 首步和后续步骤的比例具有不同构成

全部首次步骤共有 $167/230 = 72.61\%$ 记录通过。把步骤编号为 2 或更大的记录合并，得到 $39/99 = 39.39\%$ 。分母 99 来自表 12 中各个后续步骤合格数的相加，不是 99 条不同路径，更不是 99 个独立任务。一条长路径会贡献多条后续记录。“后续减首次”的差为

$$100 \left(\frac{39}{99} - \frac{167}{230} \right) = -33.21 \text{ 个百分点}.$$

这个数描述的是两组已经观察到的记录，不是把同一批任务全部强制多修改一次之后会出现的变化。

为了说明这些摘要在一个参考抽样模型下会如何波动，我们以任务为整体，从 182 个任务中有放回抽样，共重复 20,000 次，固定随机种子为 20260906。每次抽中一个任务，都保留它的全部原始路径及合格步骤记录，再利用汇总计数重新计算相应比例。重抽样结果的第 2.5 和第 97.5

表 13: 已观察摘要及 95% 任务整群百分位参考区间。百分点差是两个比例相减；已观察长度以送审版本转移为单位。

所计算的量	估计值	参考区间
首次步骤通过比例	72.61%	[66.40, 78.60]%
后续步骤通过比例	39.39%	[24.84, 65.71]%
后续减首次，单位为百分点	-33.21	[-48.39, -7.49]
固定路径退出之前通过的比例	89.57%	[85.40, 93.53]%
到通过或退出的平均已观察长度	1.4304	[1.2271, 1.6955]

百分位数构成表 13 中的 95% 任务整群参考区间。这样保留了任务内部记录的依赖结构，但没有证明不同任务相互独立，也没有纠正历史选择机制。第 6.5 节解释了这类参考区间的含义。

这些量是汇总任务计数之后的比率，不是无论一个任务贡献多少路径或记录，都给它相同权重的平均值。因此，它们与第 6 节的任务等权修改边分析在加权方式上不同。后续步骤的区间较宽，是因为这些记录数量有限，而且很不均匀地分布在任务之间。对于已经完整枚举的档案，表中比例除四舍五入外都是精确描述；区间讨论的是在任务独立、可交换、记录选择机制相同等条件下，假想重复抽样的波动。这些条件并没有由历史档案本身得到确认。




图 2: 同一组过程信息的图示。左侧为原始 230 条路径中的累计通过和退出比例；右侧为首次与后续已观察步骤的通过比例及任务整群百分位参考区间。图描述审核记录路径，不估计多编辑一次的效果。

7.4 两组对数赔率模型及其系数

过程模型比较首次和后续步骤两组记录的通过均值。使用对数赔率尺度，

$$\text{logit}(r) = \log\left(\frac{r}{1-r}\right), \quad r = \frac{\exp(u)}{1 + \exp(u)} \quad \text{当 } u = \text{logit}(r).$$

结果变量针对实际观察到的合格记录，两组可以具有不同的任务构成。

用 s 给任务编号，用 e 给同一任务中的不同路径编号，再用 j 给一条路径内的步骤编号。对于一条已经观察到的合格记录，如果结果为记录通过，就令 $Y_{sej} = 1$ ；否则令 $Y_{sej} = 0$ 。再令 L_j 表示是否属于后续步骤： $j = 1$ 时为 0， $j \geq 2$ 时为 1。最后，用 μ_{sej} 表示相应已观察记录组中这个二元结果的平均值。拟合的方程为

$$\text{logit}(\mu_{sej}) = \alpha + \beta L_j. \quad (10)$$

α 是首次步骤的对数赔率, β 是到了后续步骤时要加在这个对数赔率上的数。因此, $\exp(\beta)$ 是后续相对于首次的赔率比。方程只拟合两个组均值, 没有为每个任务单独设定基线, 也没有控制任务难度。

分析使用针对二元结果的广义估计方程, 以工作独立性方式计算, 并采用任务聚类稳健协方差。^[9] 在这个简单的两组情形中, 拟合均值恰好就是两组实际比例。因此, 可以直接用组内计数核对系数:

$$\begin{aligned}\hat{\alpha} &= \log(167/63) = 0.974859, \\ \hat{\beta} &= \log(39/60) - \log(167/63) = -1.405642.\end{aligned}$$

首次步骤共有 63 条未通过记录, 后续步骤有 60 条。把 $L_j = 0$ 代入对数赔率的逆变换, 得到 0.726087; 把 $L_j = 1$ 代入, 得到 0.393939。对两者的对数赔率之差取指数, 则有

$$\exp(\hat{\beta}) = \frac{39/60}{167/63} = 0.2452.$$

这是两个已观察记录组的赔率比, 不是修改的因果效果估计。

7.5 任务聚类协方差与参考检验

来自同一个任务的多条记录可能共享候选历史、要求与审核条件。把 329 行全都当成互不相关的观察, 会忽略这种结构。协方差按任务聚类, 以处理任务内部依赖; 两个拟合比例保持不变。

“工作独立性”是一种计算选择的名称, 不是认为连续提交实际上独立的研究发现。这个修正也不会让不同任务变得独立: 共享依赖、模型、规则或收集批次都可能使任务相互关联。聚类处理更没有消除任务难度, 也没有消除哪些路径能够到达后续步骤的选择机制。

得到的 $\hat{\beta}$ 的稳健标准误为 0.413295。近似的 95% 瓦尔德区间使用正态参照与任务聚类协方差。在对数赔率尺度上,

$$-1.405642 \pm 1.96(0.413295) \approx [-2.215685, -0.595599].$$

对两个端点取指数, 得到赔率比区间 $[0.1091, 0.5512]$ 。把系数除以标准误, 约得 -3.4011 ; 与标准正态参考分布比较, 得到名义上的双侧 p 值 0.0006712。这里的原假设是 $\beta = 0$, 等价于首次和后续的拟合均值相同, 或赔率比为 1。和第 6 节的检验一样, 这是以指定条件为前提的参考计算, 不检验数学语义正确性。

协方差还使用各任务的贡献独立重建过, 与软件计算的最大绝对差为 2.5×10^{-16} ; 独立复核也复现了按任务重抽样的结果。这检查的是指定输入和公式的计算是否一致, 不认证记录选择机制, 更不建立观察关联的因果解释。

作为对照, 如果强制只使用一个共同均值, 便得到汇总比例 $206/329 = 0.626140$ 。对于 n 条记录中的 d 次通过, 独立伯努利工作似然为

$$\mathcal{L}(r) = r^d(1-r)^{n-d}, \quad 0 < r < 1.$$

令工作对数似然 $\ell(r) = \log \mathcal{L}(r)$, 则

$$\ell(r) = d \log r + (n-d) \log(1-r), \quad \ell'(r) = \frac{d}{r} - \frac{n-d}{1-r}.$$

令导数等于零, 得到 $d(1-r) = (n-d)r$, 所以 $r = d/n$ 。当通过和未通过都出现时, 二阶导数为负, 因此这里是最大值。代入已观察的 $d = 206, n = 329$, 就得到上面的汇总比例。

这是独立伯努利工作似然，不是依赖形式尚未指定的整个任务过程的完整联合似然。把这个方便的函数最大化，不会证明它所假定的独立性。另外，限制 $\beta = 0$ 只是在比较两个已观察记录组的均值。命题 2 中的恒定条件概率，要求在每一种合格过去历史之后都相等，这是强得多的陈述。这个两组检验既不认证，也不能全面检验那个更强的模型；尤其不能据此说多做一次修改会导致成功概率降低。

7.6 为什么选取有后续观察的任务会改变首步组

182 个任务中，只有 39 个任务贡献后续步骤记录。如果看完整段历史之后再选出这些任务，它们的首次步骤有 61 条记录，其中 12 条通过，即 19.67%。此时，后续记录的 39.39% 看起来高于选中任务的首次比例；而在与完整首次组的 72.61% 比较时，它又更低。算术没有错，但是人群构成变了。

把这 61 条首次记录拆开，原因就清楚了。其中 45 条属于后来确实继续的路径。按照第一次通过就停止的规则，这些首次步骤必然全部未通过，所以它们必然是 0/45。其余 16 条是这 39 个任务中另外一些路径的首次步骤，其中 12 条通过。因此， $61 = 45 + 16$ ，而 $12 = 0 + 12$ 。因为任务有后续观察才把任务选进来，实际上就保留了许多“为了能够继续，首次必须未通过”的记录。

相对于第 1 步，这个筛选使用了未来信息。它不是把同一批任务平衡地分配到两种修改次数下进行比较。方向反转本身不能辨识改善机制、难度机制或因果效果。给它套用某个统计悖论的名字，也不能代替对分母的解释。

作为一个有限的影响检查，每次删去一个任务重新计算，后续减首次的差落在 -36.07 至 -23.57 个百分点之间，赔率比落在 0.2156 至 0.3593 之间。删去任何单个任务都没有使汇总关联反向，但这不解决任务间依赖或档案选择问题。加入中置信度修改边还可能重新连接路径，改变失败起点人群本身。那属于不同人群的敏感性问题；本节继续使用原始高置信度路径。

因此，过程结果作出的结论有明确范围：描述指定历史重建中，记录通过与退出何时发生，并量化记录结果与已观察过程位置之间的关联。它不估计多编辑一次的因果价值，不估计数学真值的概率，也不估计未观察继续策略下的等待时间。随附的冻结输入和脚本让这些具体计算可以复现，没有增加新的审核实验。

8 把结果联系起来

8.1 数学结果的含义

测量结果说明了从一项检查中恢复信息的限度。正确程序与错误程序若得到相同的记录描述，只使用这份描述的规则就必须同样处理两者。在八个可执行布尔样例中，把两道检查通过解释为接受会错判五个；仍然只用这两道检查的最优强制二分类规则，也至少错判三个。要区分这些程序，需要增加观察，而不只是重新计算已有输出。

过程结果说明，概率模型必须同时交代观察规则。条件通过概率恒定，与后续步骤剩余路径较少并不矛盾。首次通过后停止、由于其他原因退出，以及只保留成功路径，会产生不同的后果。这些结论来自指定模型；重建出一条历史路径，还不足以确认模型假设。

识别结果给出了判断是否还需要证据的准则：如果每个允许的补全都给出相同差值，现有信息便确定了它；否则，增加观察才可能缩小范围。夏普利分摊能够概括完整比较，但不会带来新的观察。

8.2 为什么两种历史趋势可以同时成立

在选定的候选修改边上，以任务等权计算的记录通过变化为正。在固定失败起点路径上，后续被观察步骤的通过比例却低于首步。两句话使用不同的对象与筛选条件，没有任何代数规则要求它们方向一致。

例如，设十个未解决任务中，八个在第一步通过，余下两个里有一个在第二步通过。通过比例从 $8/10 = 80\%$ 降为 $1/2 = 50\%$ ，已有通过记录的任务却从八个增加到九个。第二组恰好由前一步没有通过的任务组成，因此其比例较低，并不能说明第二次修改伤害了任务。这是一个说明性例子。

真实项目还有更多复杂性：同一个任务可能有多条路径，候选和审核条件可能改变，路径也可能离开规定的图结构。因此，实际的任务配对分析与过程分析分别保持自己的定义，不把说明性例子当作已经拟合的数据模型。它们得到的正、负差值都涉及记录结果，而不是独立确认的数学质量。

8.3 逻辑、统计与题意上的不确定性

报告使用了三种不同的不确定性。把它们分开，公式的含义就更容易理解。

- **尚未观察的比较：**一个分数缺失，所以多张表都可能与现有信息相容。在有效约束下补全这些表，可以得到答案的逻辑范围。
- **统计参考计算：**把保留任务视为来自某种明确、可以设想重复的抽样机制。标准误或重抽样区间描述在该机制下的变化；能否适用于观察任务之外，取决于相关假设。
- **尚未解决的题意解释：**我们没有独立参考来判断候选是否表达了预期数学。针对通过标签得到再窄的抽样区间，也不能补上这个参考。

布尔对照已列举全部输入，并观察到相应输出；其局限在于，这个任务上的结论能够推广到多大范围。因此，有限样例的错误下界、缺失格的逻辑界和抽样区间具有不同含义。

8.4 后续比较研究的条件

如果以后要比较题意评价能力，先确定任务怎样选取，以及具体测量哪个结果。例如，可以请独立裁定者按明确参考判断候选是否满足某一条要求。向被比较的评价器提供同一候选、同一要求和同一范围的证据；在任务内部比较它们的答案，保留无法判断的情况，并将同任务的重复观察放在一起。构造反例集仍然有用，但它与独立抽样的评估集回答不同问题。

还可以用一个简单规划关系，理解精度与独立任务数量的联系。设 $h > 0$ 是任务配对平均差的近似 95% 区间所期望的半宽。设 σ_D 是拟议抽样总体中任务差值的标准差，应来自合适的先导研究，或采用有依据的保守上界。设 S_{plan} 是计划纳入的任务数量，不是运行次数或修改边数。在任务独立抽样的条件下，标准误近似为 $\sigma_D / \sqrt{S_{\text{plan}}}$ 。正态参考下的 95% 区间，其半宽近似为标准误的 1.96 倍。

要求半宽不大于 h ，依次得到

$$1.96 \frac{\sigma_D}{\sqrt{S_{\text{plan}}}} \leq h, \quad \sqrt{S_{\text{plan}}} \geq \frac{1.96 \sigma_D}{h}, \quad S_{\text{plan}} \geq \frac{1.96^2 \sigma_D^2}{h^2}.$$

例如，若仅为说明而取标准差 0.20、目标半宽 0.05，右侧约为 61.47，在这个近似下提示至少需要 62 个任务。这些是规划时设定的输入，不是本研究给出的估计值；62 也不是已经对本项目

论证充分的建议数量。小样本修正、依赖关系、参考质量和实际抽样设计都可能改变计算。在这个简单关系中，把目标半宽减半，大约需要四倍的独立任务；重复运行同一候选不会创造这些任务。

后续过程研究还需要事先确定：路径何时开始、哪些下一步符合观察条件、观察何时停止，以及退出怎样记录。这些决定应当使用下一次结果出现之前的信息。随后，可在隔离的任务组或较晚时间段检验预测，回答一个明确的实际使用问题。本报告提供可复算的历史描述和具体测量核查，帮助设计这种研究，但不声称后续研究已经完成。

9 局限与复现

9.1 结果没有建立什么

历史材料是观察性、回顾性且经过筛选的。按任务归组保留了重复观察之间的联系，却不能消除选择偏差，也不能确认不同任务彼此独立。共同的数学依赖、审核者和执行条件仍可能带来依赖。统计区间采用第 6 节和第 7 节说明的参考解释。

要求检查与历史定义的解释均有智能体参与，没有经过独立专家参照的裁定。定义见证确认指定形式谓词之间的关系，布尔对照穷尽一个只有四种输入的任务；二者都不能给出全部历史的题意评价准确率。

可执行检查使用记录的 Lean 与 Mathlib 环境，没有完整重建每份候选最初的环境，因此当前编译失败未必是原有缺陷。见证由记录的 Lean 安装检查，没有采用第二套外部内核实现。部分重建步骤复用了原代码。独立统计复算检查冻结输入和公式，哈希值检查文件与所给清单是否一致；二者都不能确认外部真实性或随机抽样。

9.2 本版范围

第 0.5.0 版按实际工作及后续分析操作重组全文，恢复第 0.3.0 版的定义入口，保留第 0.4.0 版的平实行文，默认读者掌握常用数学记号和统计基础。既有论证、比较例、实证表格及推断边界完整保留；没有新增实验或拟合模型，此前版本未改。

9.3 源文件与复现

运行 `python -B build_reports.py`，即可通过 Tectonic 编译 `latex/zh/` 与 `latex/en/` 中的 LaTeX 源稿及 `latex/figures/` 中的图件，输出两份 PDF 至 `output/pdf/`。字体与构建要求见 `README.md`；版式检查及目录迁移构建均使用所记录的 Windows 字体环境。

`analysis/` 保留第 0.2.0 版的冻结输入、脚本、结果和依赖要求；编译报告无需重跑分析。便携输入复现所规定的投影，原始全历史收集仍需原档案。分类与连续性来源、目录映射及公开仓库见附录 B。交付记录将源码与 PDF 绑定到内容和版式检查。

9.4 智能体辅助

智能体参与了实现、部分题意解释、数学与统计核查及写作。此前的详解版采用了多个撰写角色，本次行文修订由主任务完成。这些检查不等于独立的人类同行评审。报告与源稿包按所链接评估仓库的分发结构准备。

A 定义与方法索引

本索引指向正文中解释对象或分析构造的位置。它不重新定义常用数学和统计记号。

对象或方法	节	页
任务、候选、审核记录、证据签名	2.1	5
连接、端点出现、连续片段	2.2	6
原始相邻关系与时间歧义	2.3	6
候选修改：高置信与中置信	2.4	6
极大连续片段与片段长度	2.5	7
失败起点、观察步骤、首次通过停止	2.6	8
候选配对与四格表	2.7	8
分数、候选、标准、环境、评价器	3.1	9
已测量、缺失、不确定、无效、不适用	3.2	9
条件差、对角变化、交互量	3.3	10
两要素夏普利分摊	3.4	11
实际历史标准与审核设置	3.5	11
测量分组与有限错误比例	4.1	12
准确率的不可识别	4.2	13
观察资格、停止与退出模型	4.3	14
鞅与可用信息	4.3.3	15
允许的补全与逻辑界限	4.4	17
线性比较量的点识别	4.5	18
诊断可答性与四种评价方法	5.3	20
定义见证中的参考谓词	5.4	20
记录通过的结果编码	6.1	22
任务等权与边等权变化	6.2	23
任务层面的配对 t 计算	6.4	24
任务整群参考区间	6.5	25
零诊断差值与未定义的 t	6.7	26
不一致编译配对与精确 McNemar 检验	6.8	27
风险行、风险集、累计通过与退出	7.2	28
已观察首步组与后续步骤组	7.3	29
两组模型、赔率比与任务协方差	7.4	30
工作似然及其限制	7.5	31
使用后续观察进行筛选	7.6	32

B 来源与相对目录

报告及主要冻结分析材料按[评估仓库](#)的目录组织。以下路径相对于随附源稿包或仓库根目录：`evidence/SOURCE_MAP.json` 将副本与原材料的相对来源和哈希对应起来。该映射用于核对来源，不把文件一致性当成科学有效性。

实际工作与留档。

`evidence/workflow/workflow.md` 与 `evidence/workflow/artifacts.md` 保留流程和材料说明。它们支持编写、构建、审核、修改及留档的背景，不意味着每条历史记录都遵循同一时期的规则。

原始相邻关系。

evidence/history/main_adjacency_partition.csv 和
evidence/history/EDA1_FINDINGS.md 记录原相邻关系成员与时间歧义口径。
evidence/history/retain_original_adjacency.py.txt 是原始程序的相关节选。

连接分类与片段重建。

evidence/history/REPAIR_TRAJECTORY_ARCHITECTURE_v3.md 说明规则；
evidence/history/classify_role.py.txt 与
evidence/history/join_segments.py.txt 保留分类和拼接代码节选。
evidence/history/transition_role_summary.csv 与
evidence/history/episode_attempt_distribution.csv 提供相应汇总计数。源码节选供
查阅，不是可单独运行的全历史收集器。

465 条边的配对分析。

analysis/inputs/edge/edge_view.jsonl、
analysis/inputs/edge/review_events.jsonl 及同目录的 manifest.json 是冻结输入。
analysis/edge_statistics.py 对应计算，analysis/edge_statistics.json 保存结果。

230 个失败起点的过程分析。

analysis/inputs/process/episodes.json 保存全部 262 个完整片段，配套清单绑定输入。
analysis/process_analysis.py 中的 derive 先选失败起点，再截取到首次通过或片段末端。
结果分别位于 analysis/process_cohort.csv、analysis/process_risk_rows.csv、
analysis/process_curve.csv 与 analysis/process_statistics.json。

编译与统计依赖。

报告入口为 latex/en/main.tex 和 latex/zh/main.tex；图位于 latex/figures/。
build_reports.py 与 README.md 说明 Tectonic 和字体要求。统计复算的库版本位于
analysis/requirements.txt；编译报告本身不需要运行统计或 Lean 实验。

本源稿包提供重建报告和复算上述统计投影所需的材料，并非全部历史档案的副本。选定 Lean 执行、定义见证和布尔对照的计数来自此前保留的核查；本版没有重新执行。其完整历史执行证据仍归属于前版证据归档，不能由这里的 LaTeX 构建记录替代。复现统计投影也不等于重新验证每一次历史审核。

参考文献

- [1] Lean. The lean language reference: Axioms. <https://lean-lang.org/doc/reference/latest/Axioms/>. Accessed 6 September 2026.
- [2] Lean. The lean language reference: Validating a lean proof. <https://lean-lang.org/doc/reference/latest/ValidatingProofs/>. Accessed 6 September 2026. Live background documentation, not the experimental toolchain lock.
- [3] NIST. Dataplot reference: McNemar test. <https://itl.nist.gov/div898/software/dataplot/refman1/auxillar/mcnemar.htm>. Accessed 6 September 2026.
- [4] NIST/SEMATECH. e-handbook of statistical methods: Analysis of paired observations. <https://www.itl.nist.gov/div898/handbook/prc/section3/prc311.htm>. Accessed 6 September 2026.
- [5] Marco Tulio Ribeiro, Tongshuang Wu, Carlos Guestrin, and Sameer Singh. Beyond accuracy: Behavioral testing of NLP models with CheckList. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 4902–4912. Association for Computational Linguistics, 2020. <https://aclanthology.org/2020.acl-main.442/>. doi:10.18653/v1/2020.acl-main.442.
- [6] SciPy Developers. Scipy reference: bootstrap. <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.bootstrap.html>. Accessed 6 September 2026.
- [7] SciPy Developers. Scipy reference: ttest_rel. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_rel.html. Accessed 6 September 2026. Calculation used SciPy 1.13.1.
- [8] Lloyd S. Shapley. A value for n-person games. Technical Report P-295, RAND Corporation, 1952. <https://www.rand.org/pubs/papers/P295.html>. doi:10.7249/P0295.
- [9] statsmodels Developers. Generalized estimating equations. <https://www.statsmodels.org/stable/gee.html>. Accessed 6 September 2026.